



UNIVERSITAT DE
BARCELONA

Grau de Lingüística

Treball de Fi de Grau Curs 2026–2027

Comparació dels patrons d'atenció humans i computacionals en la detecció de sexisme

Pol Pastells i Vilà

Tutora: Mariona Taulé Delor



Barcelona, 1 de setembre de 2026



Amb aquest escrit declaro que sóc l'autor/autora original d'aquest treball i que no he emprat per a la seva elaboració cap altra font, incloses fonts d'Internet i altres mitjans electrònics, a part de les indicades. En el treball he assenyalat com a tals totes les citacions, literals o de contingut, que procedeixen d'altres obres. Tinc coneixement que d'altra manera, i segons el que s'indica a l'article 18, del capítol 5 de les Normes reguladores de l'avaluació i de la qualificació dels aprenentatges de la UB, l'avaluació comporta la qualificació de "Suspens".

Barcelona, a 1 de setembre de 2026

Signatura:

Firmado por POL PASTELLS I VILÀ - DNI
***9094** el día 01/09/2026 con un
certificado emitido por SubCA CIUTADANIA
Q (G3) A.2

Índex

Resums	4
1 Introducció	5
2 Marc teòric	6
2.1 Categorització del sexisme en continguts multimèdia	6
2.2 Corpus d'origen: MuSeD	6
2.3 Lectura i eye-tracking	8
2.4 Comparació entre atenció humana i computacional	10
2.5 Enfocament tripartit i hipòtesis del treball	13
3 Metodologia	14
3.1 Selecció de texts de MuSeD	14
3.2 Procediment experimental	15
3.3 Models de llenguatge	16
3.4 Mètodes d'interpretabilitat	17
3.5 Comparació amb patrons humans	18
4 Resultats	19
4.1 Anotacions dels participants	19
4.2 Record estimulat	21
4.3 Distribucions d'atenció: comparació amb les anotacions de segments	22
4.4 Anàlisi de regressions oculars	24
4.5 Mètriques d'eye-tracking	29
4.6 Comparació entre atenció humana i prominència de models	31
5 Conclusions	37
Referències	40
A Funcionament de l'eye-tracker	44
B TFD i regressions	45
C Calibratge i validació	47

D	Prominència per categories gramaticals	48
E	Ablació del filtratge de paraules buides	49
F	Llista completa de texts	50

Resums

La detecció del sexisme és una preocupació creixent en el processament del llenguatge natural (PLN), però sabem poc sobre els patrons per identificar-lo. Comprendre els patrons pot aportar informació sobre els processos cognitius i millorar la interpretabilitat dels models.

En aquest treball comparem la lectura humana amb la prominència atribuïda pels models. Persones i models se centren en regions coincidents però diferents, i les persones són més sensibles als indicis pragmàtics del sexisme implícit.

Dissenyem un experiment d'eye-tracking amb 10 participants que llegeixen texts en castellà d'un corpus de sexisme. Els participants emeten judicis binaris, valoren la confiança i participen en entrevistes de record estimulat. Paral·lelament, extraïem explicacions de models de llenguatge codificadors.

Correlacionem les durades de fixació amb les atribucions dels models i comparem les fonts amb les anotacions de referència. En fonamentar l'estudi de la interpretabilitat en dades cognitives, aquest treball connecta la psicolingüística i el PLN.

Paraules clau: Detecció de sexisme, eye-tracking, PLN, interpretabilitat

Abstract:

Sexism detection is a growing concern in NLP, yet little is known about how humans and language models allocate attention when identifying it. Understanding these patterns can illuminate cognitive processes, improve interpretability, and inform annotation guidelines.

In this work, we compare human reading behavior with model attention mechanisms. We hypothesize that humans and models attend to partially overlapping but distinct textual regions, with humans showing greater sensitivity to pragmatic cues, particularly in implicit sexism.

We design an eye-tracking experiment with 10 gender-balanced participants reading Spanish texts from MuSeD, a multimodal sexism dataset. Participants provide binary judgments and confidence ratings, followed by stimulated recall interviews. Computationally, we extract attention from encoder language models.

We correlate fixation durations with attention weights, evaluating both against gold-standard sexist spans. By grounding interpretability in cognitive data, this work bridges psycholinguistics and NLP, with implications for bias detection.

Keywords: Sexism detection, eye-tracking, NLP, interpretability

1. Introducció

El sexisme és una forma de discriminació basada en el sexe o el gènere que afecta tots els àmbits de la societat. Amb l'auge de les xarxes socials, el contingut sexista s'ha amplificat i diversificat. Per això, la detecció automàtica és cada vegada més necessària en l'àmbit de la moderació de continguts (De Grazia et al., 2025).

En paral·lel, els models de processament del llenguatge natural (PLN) basats en l'arquitectura *transformer* (Vaswani et al., 2023) han assolit resultats notables en tasques de classificació de texts, com ara la detecció de discurs d'odi i de sexisme (Gandhi et al., 2024; Malik et al., 2025; Plaza et al., 2025). Aquests models incorporen mecanismes d'atenció que determinen quines parts del text reben més pes durant el processament. Tanmateix, fins a quin punt aquests patrons d'atenció reflecteixen els processos cognitius humans continua sent una qüestió oberta (Jain & Wallace, 2019; Wiegrefe & Pinter, 2019).

La tecnologia de seguiment ocular (*eye-tracking*) ofereix una finestra als processos atencional humans durant la lectura (Rayner, 1998, 2009). Mètriques com la durada total de fixació, la durada de la primera fixació o el nombre de regressions permeten identificar quins elements lingüístics capten l'atenció del lector i quins requereixen un processament més profund (Clifton Jr et al., 2007). La comparació entre l'atenció humana—mesurada amb *eye-tracking*—i les explicacions computacionals dels *transformers* constitueix un camp emergent. Pot aportar informació tant sobre la interpretabilitat dels models com sobre els processos cognitius implicats en la detecció de contingut ofensiu.

L'objectiu principal d'aquest treball és comparar els patrons d'atenció humans i computacionals durant la detecció de sexisme en texts. Concretament, es plantegen els objectius següents:

1. Recollir dades de seguiment ocular de participants humans durant la lectura de texts amb contingut sexista i no sexista.
2. Extreure les atribucions de models *transformer* preentrenats davant dels mateixos texts.
3. Analitzar i comparar els patrons d'atenció humans i computacionals per determinar el grau d'alineament entre tots dos.
4. Explorar si les divergències entre atenció humana i computacional es relacionen amb les dificultats de classificació dels models.

2. Marc teòric

2.1. Categorització del sexisme en continguts multimèdia

L'estudi de De Grazia et al. (2025) estableix els fonaments conceptuals per a la classificació del sexisme en continguts multimèdia de les xarxes socials. Defineixen el sexisme com “prejudici i discriminació basats en el sexe o el gènere”, en un sentit ampli, que inclou l'orientació sexual i la identitat de gènere. Aquesta definició segueix l'enfocament d'O'Brien (2009), que conceptualitza el sexisme com una ideologia que reproduceix i marginalitza subjectivitats que no s'ajusten a les normes heteropatriarcal.

Dins d'aquest marc conceptual, De Grazia et al. (2025) identifiquen diversos reptes per a la classificació del sexisme:

- La distinció entre sexisme implícit i explícit. Les formes implícites, com els estereotips subtils, són més subjectives, depenen del context cultural i obtenen un acord menor entre els anotadors.
- La importància del context multimodal. Alguns tipus de sexisme, com l'objectificació, només es poden detectar adequadament si s'analitzen diverses modalitats, i no únicament el text. Això pot generar contradiccions quan un missatge textual neutre s'acompanya d'elements visuals sexistes.
- La dependència cultural del fenomen, que pot provocar una variabilitat notable en els patrons d'atenció dels participants.

Aquests factors tenen implicacions directes en els patrons d'atenció entre humans i models d'intel·ligència artificial, especialment en categories de sexisme subtils o contextuals, i motiven l'ús de tècniques d'eye-tracking i d'interpretabilitat computacional que desenvolupem a continuació.

2.2. Corpus d'origen: MuSeD

El corpus utilitzat en aquest treball prové de MuSeD (*Multimodal Sexism Detection Dataset*) (De Grazia et al., 2025), un conjunt de dades per a la detecció de sexisme en vídeos en castellà. MuSeD consta de 400 vídeos extrets de dues xarxes socials: TikTok i BitChute. TikTok, tot i prohibir explícitament la misogínia a les seves directrius comunitàries, continua allotjant contingut sexista de manera explícita i implícita; BitChute, en canvi, és una plataforma de baixa moderació. El

conjunt de dades és aproximadament equilibrat, amb un 48,5% de vídeos etiquetats com a sexistes i un 51,5% com a no sexistes.

2.2.1. Recollida de dades

Els vídeos es van recollir entre maig i octubre de 2024. Es va elaborar una llista de 187 *hashtags* en castellà que cobria temàtiques relacionades amb el gènere, la sexualitat, el feminisme i la discriminació per sexe o orientació sexual. Aproximadament el 90% dels vídeos provenen de TikTok. Les transcripcions textuais es van obtenir automàticament amb Whisper (Radford et al., 2022) i van ser revisades i corregides per una lingüista professional.

2.2.2. Procés d'anotació

L'anotació es va dur a terme en tres nivells: text (transcripció i OCR¹—text escrit al vídeo), àudio i vídeo complet. Sis anotadors amb formació en lingüística, dividits en dos equips, van classificar cada ítem com a sexista o no sexista. Addicionalment, van etiquetar els segments (*spans*) textuais o segments de vídeo que motivaven la classificació. El marc d'anotació distingia quatre tipus de contingut sexista:

- **Estereotip** (*Stereotype*): afirmacions sobre propietats que suposadament diferencien homes i dones a partir de creences estereotipades (Samory et al., 2021). Reforça rols de gènere tradicionals i presenta diferències com a “naturals” o biològicament determinades.
- **Desigualtat** (*Inequality*): discurs que nega l'existència de desigualtats de gènere o presenta el moviment feminista com una amenaça per als homes. Inclou la victimització masculina en polítiques d'igualtat.
- **Discriminació** (*Discrimination*): contingut que discrimina per orientació sexual o identitat de gènere i que denigra la comunitat LGBTQ+ (Chakravarthi et al., 2021).
- **Objectificació** (*Objectification*): representació de les dones com a objectes físics valorats principalment per la seva utilitat (Szymanski et al., 2011).

Entre els vídeos sexistes, el 56,2% correspon a estereotips, el 39,2% a desigualtat, el 15,5% a discriminació i el 3,6% a objectificació. Com que un mateix ítem pot rebre més d'una categoria, aquests percentatges no han de sumar el 100%. Cal destacar que, si un ítem conté una crítica, una denúncia o el relat d'una experiència sexista, s'etiqueta com a no sexista. A més, també es va anotar la implicitud del sexisme (Schmeisser-Nieto et al., 2022), així com la presència d'humor o ironia.

¹Optical character recognition.

2.2.3. Estructura del corpus

Cada instància del corpus proporciona les variables següents, rellevants per als criteris de selecció descrits a la [Secció 3.1](#):

- **sexist_text**: etiqueta binària que indica si el text, aïllat del context audiovisual, es considera sexista.
- **sexist_video**: etiqueta binària equivalent, però basada en el contingut multimodal complet (vídeo, àudio i text).
- **sexist_soft**: valor entre 0 i 1 que reflecteix el grau d'acord entre els anotadors. Té quatre valors possibles: 0, 0,33, 0,67 i 1.
- Anotacions a escala de segments: fragments concrets del text marcats com a sexistes per part dels anotadors, que permeten identificar quines parts del text motiven l'etiqueta global.

2.2.4. Acord entre anotadors

La fiabilitat de les anotacions es va mesurar amb la κ de Fleiss (Fleiss, [1971](#)). En l'anotació textual, es van obtenir valors de $\kappa = 0,719$ (equip 1) i $0,717$ (equip 2). En l'anotació del vídeo complet, els valors van augmentar fins a $0,834$ i $0,853$, respectivament, cosa que indica un acord *substancial* (Landis & Koch, [1977](#)). La millora associada a la incorporació de modalitats addicionals suggereix que, en alguns casos, el sexisme és difícil de detectar només a partir del text. Això pot deure's a la dificultat d'identificar formes implícites o a la contradicció entre el contingut verbal i el no verbal. Precisament aquest fet motiva el criteri de coherència entre modalitats descrit a la metodologia ([Secció 3.1](#)).

2.3. Lectura i eye-tracking

La lectura implica una sèrie de moviments oculars: fixacions—períodes de 200–300 ms en què l'ull està relativament estàtic—intercalades amb sacades ràpides, que duren aproximadament 30–50 ms (Rayner, [1998](#)). Durant les fixacions, el lector processa la informació d'una àrea focal de 3–4 lletres; la informació perifèrica guia les sacades successives cap a les paraules següents. L'eye-tracking és una tècnica no invasiva que permet registrar els moviments oculars durant la lectura. Ens aporta informació indirecta, però objectiva, sobre els processos cognitius (Conklin et al., [2018](#)). Aquesta idea s'anomena *mind-eye hypothesis* (hipòtesi ull-ment) (Just & Carpenter, [1980](#)). La hipòtesi es basa en dues premisses (Pickering et al., [2004](#)): (1) allò en què es fixen els ulls s'està processant mentalment i (2) com més temps es dedica a una regió, més esforç cognitiu requereix.

Així doncs, els moviments oculars proporcionen una mesura en temps real del processament lingüístic: les fixacions reflecteixen l'atenció i l'esforç cognitiu, mentre que les sacades indiquen els moviments entre diferents regions del text. En la literatura sobre eye-tracking, s'anomena àrea o regió d'interès cada zona de la imatge que es vol estudiar. En els experiments de lectura, les àrees d'interès poden correspondre a caràcters, paraules, sintagmes o fragments de text. En aquest treball, les àrees d'interès corresponen a paraules. Les mètriques d'eye-tracking més utilitzades en la recerca sobre lectura inclouen:

- **Durada total de fixació (TFD, *Total Fixation Duration*)**: suma de les durades de les fixacions sobre una paraula al llarg de tota la lectura, incloses les relectures. Capta l'atenció acumulada i el processament deliberat, i és especialment sensible a la dificultat semàntica i pragmàtica del text. En aquest treball és la mètrica principal per comparar l'atenció humana amb les distribucions de prominència dels models, ja que totes dues representen l'atenció acumulada sobre els tokens. La TFD es normalitza pel temps total de fixació de cada text.
- **Durada de la primera fixació (FFD, *First Fixation Duration*)**: durada de la primera fixació sobre una paraula. Capta la reacció inicial al contingut i reflecteix el processament superficial i el reconeixement lèxic ràpid (Rayner, 2009). Una FFD més llarga pot indicar que una paraula és menys predictable o més complexa cognitivament.
- **Nombre de fixacions (FC, *Fixation Count*)**: nombre total de fixacions sobre una paraula. Reflecteix l'atenció acumulada, incloses les relectures i el processament deliberat (Rayner, 2009).
- **Regressions**: moviments oculars cap enrere (dreta a esquerra en escrits d'esquerra a dreta) que reflecteixen reprocessament, verificació o resolució d'ambigüitat. Taxes més altes de regressió indiquen fragments del text que generen més dificultat de processament.

Aquestes mètriques informen no només del processament superficial, com el reconeixement de paraules, sinó també de la integració semàntica i pragmàtica. Per a més informació sobre la TFD i les regressions, vegeu l'[Apèndix B](#).

2.3.1. Corpus d'eye-tracking per al PLN

En el camp del PLN, existeixen diversos corpus d'eye-tracking per entrenar i avaluar models computacionals. Aquests corpus permeten entrenar models predictius de fixacions i explorar la relació entre l'atenció humana i els mecanismes d'atenció dels models de llenguatge.

ZuCo (Hollenstein et al., 2018) és un recurs simultani d'electroencefalografia (EEG) i eye-tracking amb 12 subjectes que llegeixen frases angleses. El corpus inclou 21.629 paraules en 1.107 frases, amb 154.173 fixacions enregistrades. Els materials inclouen frases de ressenyes de pel·lícules amb etiquetes de sentiment i paràgrafs biogràfics de Wikipedia amb relacions semàntiques anotades. Els participants van executar tres tasques: dues de lectura normal, amb materials diferents, i una tasca específica de cerca de relacions. Els autors van extreure diferents característiques oculars per a cada paraula i frase, com la FFD o el temps total de lectura.

ZuCo 2.0 (Hollenstein et al., 2020) amplia el predecessor amb 18 subjectes i contrasta la lectura normal amb la lectura específica per la tasca. Demostra que l'objectiu de la lectura modifica profundament els patrons d'atenció visual, una qüestió que també abordem quan comparem l'atenció humana (lectura per comprensió) amb les atribucions del model (classificació de sexisme).

Arcos (2025) aplica dades d'eye-tracking, freqüència cardíaca i EEG a la detecció de sexisme en mems. Mostren que els mems sexistes requereixen més esforç cognitiu, que es manifesta en temps de reacció més llargs i un nombre de fixacions superior. Aquest efecte augmenta progressivament dels mems no sexistes als mems sexistes crítics. A més, el seu model, que integra text i imatge amb EEG i eye-tracking, aconsegueix una AUC² de 0,8 en la detecció binària. Això suposa una millora del 3,4% respecte d'un model base que només utilitza text i imatge. Per tant, les respostes fisiològiques proporcionen un senyal complementari al contingut, i la fusió multimodal millora el rendiment en la detecció de sexisme.

2.4. Comparació entre atenció humana i computacional

La intersecció entre els patrons d'atenció humans i els mecanismes d'atenció computacionals s'ha convertit en un tema rellevant per a la interpretabilitat (Lipton, 2018) de la IA i per a la lingüística cognitiva. Sood et al. (2020) van proposar un mètode sistemàtic per comparar l'atenció humana i la computacional en tasques de comprensió lectora. Per fer-ho, van utilitzar el corpus d'eye-tracking MQA-RC³, amb 23 subjectes. Van observar que, en els models basats en LSTM i CNN, hi havia una correlació significativa entre la similitud amb l'atenció humana i el rendiment (Spearman $\rho = -0,73$ i $-0,72$, respectivament, $p < 0,001$). Aquesta relació, però, no es mantenia en models Transformer com XLNet (Yang et al., 2019) ($\rho = -0,16$, $p = 0,381$). A més, la divergència de Kullback-Leibler (KL) entre l'atenció LSTM i humana (0,018) és significativament menor que la de XLNet (0,022), fet que suggereix que diferents arquitectures

²L'AUC (*Area Under the Curve*) representa l'àrea sota la corba ROC, que relaciona la taxa de veritables positius amb la taxa de falsos positius.

³MovieQA Reading Comprehension, QA=Question Answering

aprenen estratègies d'atenció diferents i que la similitud amb l'atenció humana no garanteix el millor rendiment. Aquesta observació té implicacions per al nostre treball: si els models Transformer no mostren una correlació significativa amb l'atenció humana, cal explorar també altres fonts d'informació, com les anotacions humanes i les dades d'eye-tracking.

Ikhwantri et al. (2023) estableixen el marc metodològic per a la comparació sistemàtica entre patrons d'atenció humans i computacionals en tasques de PLN. Analitzen tres tasques (anàlisi de sentiment, classificació de relacions, pregunta-resposta), quatre mètodes d'interpretabilitat (gradient simple, Integrated Gradients, pertorbació d'entrada i atenció) i tres arquitectures (LSTM, CNN i Transformer). Es basen en dos conjunts de dades d'eye-tracking: ZuCo i MQA-RC.

Per mesurar la conformitat entre la prominència del model i l'atenció humana, proposen calcular la divergència KL entre la distribució de prominència sobre les paraules d'entrada—obtinguda amb un mètode d'interpretabilitat—i una característica d'eye-tracking (FC o FFD). Una KL més petita indica una similitud més gran entre les distribucions: el model assigna més prominència a les mateixes paraules que les persones. Els seus resultats principals són:

- La KL és consistentment més petita amb FFD que amb FC en gairebé totes les combinacions de tasques i mètodes.
- Els mètodes basats en gradients obtenen una KL menor que els mètodes de pertorbació (*input perturbation*, IP) i d'atenció (Attn) en les tasques d'anàlisi de sentiment i classificació de relacions. En canvi, en la tasca de QA amb resposta múltiple, basada en texts més llargs, l'atenció és el mètode amb la KL més baixa.
- El Transformer mostra la KL més baixa en la majoria de les combinacions, excepte amb el mètode IP en l'anàlisi de sentiment i amb Attn en la classificació de relacions.
- En anàlisi de sentiment, els humans centren l'atenció en noms propis, adjectius, noms, adverbis i nombres; els models amb el millor mètode (Grad-Transformer) sobrevaloren els adjectius, però subvaloren els noms propis i els nombres. En classificació de relacions, els models no capten bé els verbs i adjectius que indiquen relacions entre entitats.
- Les corbes KL–Performance que proposen tendeixen a ser decreixents en tasques de classificació (més conformitat implica més rendiment), mentre que en QA són més planes o irregulars.

Els resultats d'Ikhwantri et al. (2023) suggereixen que la relació entre conformitat humana i rendiment varia segons la tasca, el mètode d'interpretabilitat i l'arquitectura. En el nostre cas, la classificació de texts és similar a les tasques de sentiment i de relacions. Per això, esperem

que els mètodes basats en gradients mostrin un alineament més gran amb l'atenció humana. A més, la nostra aproximació tripartida (anotacions, eye-tracking i models) ens permet abordar la necessitat d'integrar diverses fonts d'informació per entendre el comportament dels models.

2.4.1. Variabilitat en explicacions: humans vs. models

Bogaert et al. (2026) comparen anotacions humanes, basades en tokens ressaltats, amb explicacions generades mitjançant Layer-wise Relevance Propagation (vegeu la Secció 3.4) per models transformer adaptats. Identifiquen diferències notables en diversos àmbits. Pel que fa a la granularitat, els humans destaquen segments més llargs i semànticament rellevants, mentre que els models produeixen atribucions més difuses a escala de token. Les persones mostren més acord en els tokens més rellevants, mentre que els models tendeixen a coincidir més quan es consideren tots els tokens. Pel que fa a la sensibilitat al tipus de contingut, els humans mostren més acord en texts d'opinió, mentre que els models són més consistents en texts de notícies.

Aquesta variabilitat en les explicacions no és exclusiva de la comparació entre persones i models; també es manifesta entre models funcionalment equivalents. L'efecte Rashomon (Breiman, 2003) estableix que els models amb un rendiment similar poden produir explicacions radicalment diferents per a una mateixa predicció. Això posa en dubte la noció de *l'única* explicació correcta d'un model. Si els models poden arribar a la mateixa conclusió per camins diferents, l'alineament amb els processos humans es converteix en un criteri de disseny explícit. En aquest context, la variabilitat de les explicacions és una propietat que cal quantificar, no pas un soroll que cal eliminar.

2.4.2. Plausibilitat i fidelitat

Adoptem el marc de Jacovi i Goldberg (2020), que distingeix entre plausibilitat i fidelitat. La plausibilitat és la mesura en què una explicació resulta convincent per a un observador humà i s'alinea amb les seves expectatives sobre els factors rellevants. La fidelitat és la mesura en què reflecteix el procés real de decisió del model.

L'enfocament tripartit que proposem permet situar cadascuna de les fonts de dades en aquest marc. Les anotacions humanes, basades en segments ressaltats, permeten avaluar la plausibilitat de les explicacions. Les dades d'eye-tracking ofereixen una mesura més objectiva dels processos d'atenció, tot i que no constitueixen una mesura directa de la fidelitat del model. La combinació de totes dues fonts permet explorar la possible tensió entre plausibilitat i fidelitat.

2.5. Enfocament tripartit i hipòtesis del treball

El nostre treball amplia el marc de Bogaert et al. (2026) incorporant dades d'eye-tracking, que capturen els patrons d'atenció visual durant la lectura. Aquesta aproximació permet establir tres comparacions: entre les atribucions dels models i els segments textuais que els anotadors humans han marcat com a rellevants; entre les atribucions dels models i les mètriques d'eye-tracking per token o regió textual; i entre els patrons d'atenció visual capturats per eye-tracking i les decisions conscients de ressaltar fragments rellevants.

A partir d'aquest marc, plantegem tres hipòtesis:

- **H1:** Els models adaptats mostraran un alineament moderat amb els patrons humans, amb diferències notables de granularitat, seguint Bogaert et al. (2026).
- **H2:** L'alineament serà major per a sexisme explícit que per a casos de sexisme implícit, humor o ironia.
- **H3:** Les tres fonts de dades proporcionaran informació complementària entre si.

3. Metodologia

3.1. Selecció de texts de MuSeD

3.1.1. Estudi pilot

Abans de la selecció final, vam dur a terme un estudi pilot amb 6 voluntaris (3 homes i 3 dones), que van llegir 11 texts de MuSeD seleccionats perquè contenien humor o ironia. El pilot va permetre identificar dues limitacions del disseny inicial: els texts eren massa llargs, ja que els participants tardaven uns 10 minuts a llegir-los tots, i calia refinar el protocol experimental (vegeu [Secció 3.2](#)). Aquestes observacions van motivar els criteris de selecció que descrivim a continuació, orientats a reduir la longitud dels texts i a garantir una durada raonable de la sessió.

3.1.2. Criteris de selecció

A partir del corpus MuSeD, es van seleccionar 40 texts (20 sexistes i 20 no sexistes) seguint els criteris següents:

1. **Coherència entre modalitats:** només es van conservar les instàncies en què les etiquetes textual i multimodal coincidien (`sexist_text = sexist_video`).
2. **Acord total entre anotadors:** es van descartar les instàncies amb valors intermedis de `sexist_soft` i només es van mantenir les que presentaven consens (`sexist_soft ∈ {0, 1}`).
3. **Longitud:** es van prioritzar els texts més curts o amb segments anotats més curts, per mantenir una durada raonable de la sessió experimental i facilitar l'anàlisi. Considerant una velocitat de lectura aproximada de 1.000 caràcters per minut, els 40 texts seleccionats suposen aproximadament 17 minuts de lectura. A aquest temps cal afegir-hi el calibratge i les entrevistes de *stimulated recall* (vegeu [Secció 3.2](#)).
4. **Comprensibilitat autònoma:** es van descartar els texts amb vocabulari estrany per a un oient catalanoparlant. Quan era necessari, es van fer petites edicions per millorar-ne la llegibilitat, com ara afegir cometes o indicar qui parla en fragments dialogats.
5. **Validació manual:** cada text candidat es va revisar individualment. Es va escoltar l'àudio original i es van inspeccionar visualment les anotacions de segments per confirmar-ne l'adequació.

Els texts sexistes tendeixen a ser més llargs que els no sexistes, i les anotacions de segments en cobreixen una proporció considerable. Les taules [3.1](#) i [3.2](#) resumeixen les estadístiques descrip-

tives i la distribució de categories dels texts seleccionats. En total, els 40 texts contenen 2.901 paraules. Observem que la llargada dels segments constitueix un alt percentatge de la llargada total dels texts. La llista completa dels texts, amb les categories binàries assignades, es troba a l'Apèndix F.

	No sexistes		Sexistes	
	Mitjana	D.E.	Mitjana	D.E.
Longitud (caràcters)	388,9	137,9	439,4	173,4
Nombre de segments	0,95	0,50	1,83	0,75
Longitud dels segments	255,7	139,6	362,7	205,3

Taula 3.1. *Estadístiques descriptives dels 40 texts seleccionats (D.E.: desviació estàndard).*

Categoria		<i>n</i>
No sex.	Crítica/denúncia	11
	Ironia	1
	Humor	2
Sexistes	Estereotips	11
	Desigualtat	7
	Discriminació	6
	Sexisme implícit	2 ^a
	Sexisme reportat	1
	Ironia	2
	Humor	2 ^b
	Objectificació	0

Taula 3.2. *Distribució de categories dels texts seleccionats. ^a Els 2 texts amb sexisme implícit també presenten estereotips. ^b Els 2 texts sexistes amb humor també presenten discriminació.*

3.2. Procediment experimental

L'estudi va comptar amb 10 participants voluntaris (5 homes i 5 dones). Tots eren estudiants o treballadors de la Universitat de Barcelona, majors d'edat i d'entre 22 i 28 anys. Dos dels participants també havien estat anotadors del corpus MuSeD.

Abans de començar, es va informar cada participant dels objectius de l'estudi i es va obtenir el consentiment informat. Se'ls va explicar que haurien de llegir 40 texts en castellà, extrets de vídeos de xarxes socials, i determinar si eren sexistes. Primer es va calibrar el dispositiu perquè l'eye-tracker funcionés adequadament (vegeu l'Apèndix C). Els texts es van mostrar en ordre aleatori. Els participants podien llegir cada text tantes vegades com fos necessari i, quan havien decidit la resposta, premien 0 per indicar “no sexista” i 1 per indicar “sexista” en un teclat d'ordinador. Se'ls demanava que valoressin el contingut d'acord amb la seva pròpia visió del món i se'ls explicava que no hi havia una única resposta correcta, perquè la tasca era subjectiva.

Després, apareixia una pantalla en què havien d'indicar la confiança en la seva elecció: 1 (poca confiança), 2 (confiança mitjana) o 3 (molta confiança). Abans de mostrar el text següent, apareixia una pantalla en blanc durant 500 ms. Els participants podien fer preguntes o corregir errors durant aquesta fase.

3.2.1. *Stimulated Recall*

Un cop acabada la lectura, es feien entrevistes breus mentre es mostrava el procés de lectura d'alguns texts amb Tobii Pro Lab, on es podien veure les fixacions i les regressions. La pantalla de l'ordinador i l'àudio de la conversa es van enregistrar amb OBS Studio. Es van seleccionar 7 texts que representaven casos interessants. Tot i que el corpus MuSeD disposa d'etiquetes de consens (*gold standard*), les etiquetes individuals revelen que l'acord entre anotadors no sempre és absolut. Per exemple, el text 4 té unanimitat en discriminació (1,0) però desacord en humor (0,67) i ironia (0,33); el text 30 mostra desacord en humor (0,67) i ironia (0,33); i el text 375 en desigualtat (0,67) i múltiples categories (0,33 cadascuna). Els texts seleccionats van ser:

- **Text 4** (sexista): ironia i humor amb desacord, discriminació unànime.
- **Text 30** (sexista): humor i ironia amb desacord, desigualtat.
- **Text 37** (no sexista segons *gold standard*): estereotips i desigualtat, però ironia i humor amb desacord alt.
- **Text 107** (sexista): sexisme implícit amb desacord baix.
- **Text 166** (no sexista): crítica i humor sense desacord en categories principals.
- **Text 375** (sexista): múltiples categories amb desacord alt (ironia, sexisme implícit, estereotips, desigualtat).
- **Text 399** (no sexista): crítica, estereotips i sexisme reportat, tots amb desacord.

Es va utilitzar la llengua amb què cada participant se sentia més còmode per conversar sobre els texts: català o castellà. Durant aquesta fase, se'ls preguntava si s'havien fixat en alguna paraula o frase per un motiu concret, o si havien pensat alguna cosa determinada sobre el text. També se'ls demanava si havien trobat difícil alguna paraula o si els havia sorprès algun concepte.

3.3. Models de llenguatge

En aquest treball utilitzem diversos models basats en l'arquitectura *transformer* (Vaswani et al., 2023), concretament models del tipus BERT (*Bidirectional Encoder Representations from*

Transformers) (Devlin et al., 2019). Són models *encoder-only* que han assolit un bon rendiment en tasques de classificació de texts. Usem mBERT, la versió multilingüe del BERT original; BETO (Cañete et al., 2023), un dels primers models adaptats específicament al castellà; i el més recent MrBERT-es (Tamayo et al., 2026), basat en ModerBERT.

El procés d'adaptació (*fine-tuning*) consisteix a modificar aquests models preentrenats per a la tasca específica de detecció de sexisme. La implementació inclou la preparació de les dades, la configuració del model i l'entrenament amb la biblioteca *transformers* de Hugging Face¹. També vam entrenar els models només amb les dades que tenien acord total entre anotadors, però les diferències respecte dels models entrenats amb totes les dades van ser negligibles.

3.4. Mètodes d'interpretabilitat

Per comprendre els patrons d'atenció dels models i comparar-los amb els patrons humans, fem servir la biblioteca Captum (Kokhlikyan et al., 2020), que proporciona diversos mètodes d'atribució. N'hem implementat quatre:

- **Saliency** (Simonyan et al., 2013): mètode basat en gradients que calcula la derivada de la sortida respecte dels *embeddings* d'entrada. És útil per identificar els tokens que tenen més impacte en la decisió del model.
- **Input $\times$ Gradient** (Shrikumar et al., 2016): multiplica l'entrada pels gradients per obtenir una mesura de la importància de cada característica. Pot proporcionar atribucions més estables que el *saliency* simple.
- **Integrated Gradients (IG)** (Sundararajan et al., 2017): calcula la integral dels gradients al llarg d'un camí que va des d'una línia base, normalment el vector nul, fins a l'entrada real. També proporciona una mètrica de convergència (*delta*) que indica la qualitat de l'atribució.
- **Layer-wise Relevance Propagation (LRP)** (Chefer et al., 2021): atribueix la predicció a les característiques d'entrada mitjançant la redistribució de puntuacions de rellevància des de la sortida fins a l'entrada. Per a una mateixa entrada, LRP produeix explicacions reproduïbles.

¹<https://huggingface.co/docs/transformers/en/index>

3.5. Comparació amb patrons humans

L'objectiu final d'aquest treball és comparar tres fonts d'informació: (i) els patrons obtinguts amb els mètodes d'interpretabilitat, (ii) els patrons humans registrats amb l'eye-tracker i (iii) les anotacions inicials del corpus. Aquesta comparació permet avaluar si els models se centren en les mateixes parts dels texts que les persones, identificar possibles biaixos o limitacions dels models i explorar si les divergències entre l'atenció humana i la computacional es relacionen amb errors de classificació.

Cal tenir en compte que els tokens d'eye-tracking corresponen a paraules senceres, mentre que els models de llenguatge treballen amb tokens subparaula. Quan una paraula es divideix en múltiples tokens, les atribucions d'aquests se sumen.

L'anàlisi comparativa es basa en les dades d'eye-tracking recollides amb el dispositiu Tobii, tal com es descriu a l'Apèndix A. Els resultats s'analitzen quantitativament i qualitativament per caracteritzar la similitud entre els dos tipus d'atenció.

Tot el codi fet servir en aquest treball, incloent-hi la implementació dels models, els mètodes d'interpretabilitat, els scripts d'anàlisi i aquest treball escrit, estan disponibles públicament al repositori GitHub: https://github.com/Pastells/eye_tracker_sexism.

4. Resultats

Aquest capítol presenta l'anàlisi de les dades de seguiment ocular—fixacions i regressions—i la seva relació amb les anotacions del *gold standard* provinents del corpus MuSeD i les explicacions dels models de llenguatge. També analitza les decisions dels participants durant l'experiment.

4.1. Anotacions dels participants

Primer examinem les anotacions binàries de sexisme i les comparem amb el *gold standard*. Com es mostra a la [Taula 4.1](#), vuit dels deu participants obtenen resultats significativament superiors als esperables per atzar. Dos participants (F2 i F4) no arriben a la significació estadística, tot i que la seva exactitud (62,5%) és superior a l'atzar. Aquests resultats indiquen que, en conjunt, els participants han resolt la tasca amb prou atenció.

Identifiquem els participants amb els codis M1–M5 (homes) i F1–F5 (dones). M3 i F5 havien estat anotadors de MuSeD i són els participants amb les exactituds més altes.

Participant	Exactitud	valor p
M3	100,0%	< 0,001 **
F5	92,5%	< 0,001 **
M1	90,0%	< 0,001 **
M5	87,5%	< 0,001 **
F1	85,0%	< 0,001 **
M2	82,5%	< 0,001 **
F3	82,5%	< 0,001 **
M4	82,5%	< 0,001 **
F2	62,5%	= 0,077 ns
F4	62,5%	= 0,077 ns

Taula 4.1. *Exactitud de cada participant comparada amb l'atzar (prova binomial, bilateral).*

4.1.1. Diferències per gènere

Prova	Estadístic	valor p
U de Mann-Whitney (exactitud per text)	$U = 1001,5$	0,035 *
Exacta de Fisher (errors en texts sexistes)	$OR = 0,72$	0,468 ns

Taula 4.2. *Comparacions de l'exactitud basades en el gènere del participant.*
OR=Oportunitat relativa.

La [Taula 4.2](#) presenta les comparacions basades en el gènere dels participants. La prova U de Mann–Whitney sobre l'exactitud per text mostra una diferència significativa, però de petita magnitud. No obstant això, aquesta diferència no es manté quan examinem específicament els

errors en texts sexistes amb la prova exacta de Fisher.

4.1.2. Confiança i dificultat de text

La confiança autoinformada dels participants (escala 1–3) està significativament calibrada amb l'exactitud: una confiança més alta s'associa amb una exactitud més gran ($\rho = 0,29$, $p < 0,001$). Malgrat la moderada correlació, la tendència és clara i significativa. De les 400 anotacions, la majoria es fan amb confiança alta: 268 amb confiança 3 (67,0%), 86 amb confiança 2 (21,5%) i 46 amb confiança 1 (11,5%). L'exactitud augmenta amb el nivell de confiança: 57% (nivell 1), 74% (nivell 2) i 90% (nivell 3). És a dir, només el 10% de les anotacions amb confiança alta (27) són incorrectes.

La dificultat dels texts és heterogènia. Els més difícils, és a dir, els que presenten menys acord amb el *gold standard*, són:

- Text 37: 50% acord (5/10 participants) – no sexista amb ironia i humor
- Text 144: 50% acord – sexista amb estereotips i desigualtat
- Text 5: 60% acord – sexista amb ironia i discriminació
- Text 30: 60% acord – sexista amb humor i discriminació
- Text 107: 60% acord – sexista amb desigualtat

Aquests texts són bons candidats per a una anàlisi més detallada, ja que podrien representar casos límit o ambigus. Dels 10 texts amb 100% d'acord, 5 són sexistes i 5 no. Els sexistes presenten majoritàriament categories explícites: *estereotips* (3 texts), *desigualtat* (2) i *discriminació* (1). Això suggereix que el sexisme explícit, basat en *estereotips* o *desigualtat*, és fàcilment identificable pels lectors. En canvi, cap dels texts amb *ironia* o *humor* apareix en aquest grup de màxima facilitat, fet que confirma que aquestes formes de sexisme subtil són més difícils de detectar.

4.1.3. Detecció per subcategories de sexisme

La [Taula 4.3](#) mostra la taxa d'error individual en la detecció de cadascuna de les subcategories de sexisme definides en el *gold standard*. L'*humor* presenta la taxa d'error més alta, del 30%, seguida de *discriminació* (23%) i *desigualtat* (23%). El text 5, classificat com a sexista amb *ironia* i *discriminació*, n'és un exemple il·lustratiu: es tracta d'un diàleg sobre identitat de gènere on l'ús d'ironia (“*Soy un hombre lesbiana*”) fa que la meitat dels participants el classifiquin com a no sexista.

Subcategoria	Errònies / Total	Taxa d'error
humor	6/20	30%
discriminació	14/60	23%
desigualtat	16/70	23%
ironia	4/20	20%
sexisme implícit	3/20	15%
estereotips	16/110	15%

Taula 4.3. *Taxa d'error individual en la detecció de texts sexistes per subcategoria. Cada anotació d'un participant sobre un text sexista és un cas independent: s'agrupen les anotacions errònies (el participant va classificar el text com a no sexista) per subcategoria del gold standard.*

Per examinar si aquestes diferències són estadísticament significatives, vam fer proves exactes de Fisher per comparar les taxes d'error entre totes les parelles de categories, amb correcció de Bonferroni. Cap comparació per parelles va resultar significativa, ni abans ni després de la correcció. Per tant, les diferències observades entre subcategories, per exemple entre *humor* i *estereotips*, podrien deure's a l'atzar.

4.2. Record estimulat

Les entrevistes de *stimulated recall* revelen tres aspectes. En primer lloc, l'ambigüitat és freqüent: els participants sovint no saben si un text és sexista, especialment quan conté ironia, humor o opinions que es poden interpretar de diverses maneres. En segon lloc, busquen pistes contextuais per resoldre aquesta ambigüitat. Per exemple, intenten identificar qui parla, quina és la seva posició ideològica o si el text descriu un fet o expressa una opinió. Finalment, els participants amb experiència prèvia amb el corpus—els anotadors de MuSeD—i els participants amb poc contacte amb el castellà mostren processos de lectura diferents: els primers reconeixen els casos i els processen més ràpidament, mentre que els segons necessiten més relectures.

Aquests resultats confirmen que la detecció de sexisme en texts és una tasca subjectiva, especialment en casos d'ironia o sexisme implícit. També justifiquen l'ús de mètriques de distribució, en lloc de comparacions binàries. A continuació presentem les observacions més rellevants de les entrevistes, agrupades per text.

Text 4. La majoria dels participants identifiquen el text com a sexista, però les estratègies de lectura varien. Alguns expressen desconfiança inicial (*“ha dubtat, canviaria segons qui ho digui”*) abans de decidir. Una participant que coneixia el corpus reconeix el cas i expressa ràbia davant l'equiparació entre pedofília i orientació sexual. En canvi, una altra no sap si l'interlocutor és a favor o en contra, i no es fixa en res en concret.

Text 30. Alguns participants contextualitzen ràpidament el text: “*ja s’espera que dirà un comentari sexista*”. D’altres no ho tenen clar o l’interpreten com a no sexista. Una participant es fixa en “ahora”, que interpreta com un possible canvi de punt de vista, i rellegeix el text perquè no sap si descriu un fet sexista o si el text és sexista en si mateix.

Text 37. Aquest text, marcat com a no sexista pel *gold standard*, genera opinions dispars. Alguns l’interpreten com a sexista perquè no diferencia entre sexe i gènere; d’altres, com una caricatura o com un atac al gènere masculí. També hi ha participants que es fixen en la ideologia del forense.

Text 107. Els participants es divideixen entre les opcions sexista i no sexista. Alguns decideixen que és sexista al final, mentre que d’altres el veuen com una simple opinió. Diversos participants no saben si parla una dona sarcàsticament o un home que fa un acudit sexista.

Text 166. Alguns el veuen com una opinió no sexista, mentre que d’altres l’interpreten com un atac al gènere masculí. Una participant es fixa en “eres un hombre malo” com a posicionament de la persona i li sembla discurs d’extrema dreta.

Text 375. La majoria entenen que podria ser una crítica, però el “*makes no sense. Gracias*” del final ho fa explícit. Una participant es fixa en “feminisme” i “todo ofende”, interpretant que primer presenta una situació i després dona la seva opinió.

Text 399. Alguns pensen inicialment que es tracta d’un cas sexista, però interpreten el missatge sencer com una crítica. Una participant es fixa en els sinònims (“*nena, abuelita, doña*”) que reafirmen la posició.

4.3. Distribucions d'atenció: comparació amb les anotacions de segments

D’acord amb la justificació del marc teòric, en les comparacions següents prenem la TFD com a mètrica principal d’eye-tracking. La FFD i la FC s’hi incorporen posteriorment com a mesures complementàries de robustesa.

Per a cada parell (participant, text), calculem quatre mètriques que comparen la distribució d’atenció del participant amb les anotacions del *gold standard*. La distribució d’atenció es basa en la TFD normalitzada per token, que expliquem a l’[Apèndix B](#); les comparacions amb FFD i FC es presenten a l’apartat [4.6.4](#).

- **Correlació de Spearman:** mesura la concordança monòtona entre dues distribucions.

- **Entropia creuada (*cross-entropy*, CE):** mesura la divergència probabilística.
- **Divergència de Kullback–Leibler (KL):** mesura la divergència informacional de la TFD respecte de l'anotació.
- **Divergència de Jensen–Shannon (JS):** versió simètrica de la KL, més interpretable.

La correlació de Spearman varia entre -1 i 1 (més alta = millor alineament). La CE té com a mínim l'entropia de la distribució de referència. La divergència KL és positiva i la JS és simètrica i està acotada a $[0, 1]$. La CE i les dues divergències indiquen millor alineament com menor és el valor.

En 10 dels texts seleccionats, o bé tots els tokens estan anotats com a segments o bé no n'hi ha cap. Per tant, aquests texts no s'inclouen en aquesta anàlisi, perquè no contenen un senyal discriminant. La [Taula 4.4](#) mostra els resultats per participant.

Participant	Spearman	CE	KL	JS
F5	$0,07 \pm 0,20$	$9,47 \pm 2,33$	$5,32 \pm 2,33$	$0,22 \pm 0,07$
F1	$0,06 \pm 0,19$	$9,65 \pm 2,12$	$5,50 \pm 2,12$	$0,24 \pm 0,07$
M5	$0,05 \pm 0,16$	$9,30 \pm 2,03$	$5,15 \pm 2,03$	$0,21 \pm 0,07$
F2	$0,04 \pm 0,21$	$9,54 \pm 2,17$	$5,39 \pm 2,17$	$0,22 \pm 0,07$
M2	$0,03 \pm 0,13$	$9,91 \pm 1,86$	$5,76 \pm 1,86$	$0,26 \pm 0,06$
F4	$0,02 \pm 0,17$	$9,57 \pm 1,76$	$5,42 \pm 1,76$	$0,23 \pm 0,06$
M1	$0,02 \pm 0,18$	$9,55 \pm 1,84$	$5,40 \pm 1,84$	$0,23 \pm 0,06$
M3	$0,02 \pm 0,17$	$10,08 \pm 2,19$	$5,93 \pm 2,19$	$0,28 \pm 0,07$
M4	$0,02 \pm 0,15$	$10,12 \pm 2,13$	$5,97 \pm 2,13$	$0,29 \pm 0,07$
F3	$0,01 \pm 0,10$	$10,07 \pm 2,06$	$5,92 \pm 2,06$	$0,28 \pm 0,07$

Taula 4.4. *Mètriques de distribució per participant (mitjana $\pm$ desviació estàndard).*

Les correlacions de Spearman són properes a zero per a tots els participants, cosa que indica una concordança gairebé nul·la entre la distribució d'atenció i les anotacions de segments. La divergència JS mitjana és 0,25 (en una escala de 0 = distribucions idèntiques a 1 = totalment diferents), fet que indica una separació moderada: no tan baixa com la que s'observa entre lectors i anotadors (0,12), però molt lluny de la divergència total (0,78–0,84) que es troba entre els models i els segments.

4.3.1. Alineament per categories de sexisme

Analitzem l'alineament entre l'atenció humana i les anotacions de segments de dues maneres complementàries. Primer examinem les mètriques de distribució dins dels segments anotats amb cada tipus d'etiqueta. La [Taula 4.5](#) presenta els resultats. Les correlacions de Spearman són baixes per a totes les etiquetes, però les divergències varien. La *desigualtat ideològica* presenta la JS més alta (0,50), mentre que *estereotips* (0,23) i *objectificació* (0,24) presenten les més

baixes. Categories implícites com *sexisme implícit*, *humor* i *ironia* mostren un alineament relativament bo, superior al de categories explícites com *desigualtat/discriminació*, *sexisme reportat* o *desigualtat ideològica*.

Etiqueta	Spearman	CE	KL	JS
desig. ideol.	$0,06 \pm 0,13$	9,20	5,98	0,50
desigualtat/discrim.	$0,06 \pm 0,15$	9,80	5,99	0,37
crítica	$0,04 \pm 0,17$	10,00	5,90	0,29
sexisme reportat	$0,01 \pm 0,11$	10,42	6,27	0,40
estereotips	$0,04 \pm 0,14$	9,40	5,25	0,23
sexisme implícit	$0,06 \pm 0,16$	9,60	5,45	0,25
objectificació	$0,06 \pm 0,14$	9,50	5,35	0,24
ironia	$0,03 \pm 0,16$	9,80	5,65	0,28
humor	$0,05 \pm 0,19$	9,70	5,55	0,26

Taula 4.5. Mètriques de distribució per tipus d'etiqueta del segment (mitjana creuada entre participants i texts).

A continuació, a la [Taula 4.6](#), separem els texts segons la presència o absència de cada categoria binària del *gold standard* i calculem la divergència JS. La presència de *desigualtat* augmenta la JS de 0,24 a 0,33, cosa que indica dificultats especials. *Humor* i *ironia* mostren patrons inversos: quan són presents, la JS disminueix fins a 0,21, mentre que augmenta fins a 0,26 quan són absents. *Objectificació* i *sexisme reportat* també presenten divergències més altes quan són presents.

Categoria	JS (negatiu)	JS (positiu)
sexista	0,24	0,27
ironia	0,26	0,21
humor	0,26	0,21
sexisme implícit	0,26	0,20
estereotips	0,25	0,26
desig. ideol.	0,24	0,33
discriminació	0,25	0,25
objectificació	0,26	0,32
crítica	0,27	0,23
sexisme reportat	0,26	0,32

Taula 4.6. Divergència JS entre els segments anotats i TFD per categoria binària. Negatiu = categoria absent; Positiu = categoria present.

4.4. Anàlisi de regressions oculars

En el conjunt de parells participant-text, detectem un total de 8.642 regressions, amb una mitjana de 216 ± 77 regressions per text. La majoria són regressions dins de la mateixa línia (*within-line*), que representen el 89,8%; les regressions entre línies (*between-line*) constitueixen el 10,2% restant. En l'anàlisi seguim la convenció de Rayner (2009): el token de destí és aquell cap

al qual es dirigeix la regressió (on torna el lector per reprocessar), i el token d'origen és aquell des del qual es produeix (on s'interromp la lectura per tornar enrere). Vegeu l'Apèndix B per a la definició completa.

4.4.1. *Baselines* individuals per participant

Participant	Taxa de regressió (%)	Mitjana FD (ms)	<i>n</i> regressions
F1	25	226	1,395
F5	21	267	1.283
M1	21	232	1.145
M4	20	252	908
F4	22	244	781
M5	17	264	685
M2	19	237	625
F3	15	268	613
F2	22	199	597
M3	15	244	495

Taula 4.7. *Baselines de regressió per participant. Taxa de regressió = proporció de fixacions que són regressions. Mitjana FD = durada mitjana de fixació.*

La Taula 4.7 presenta la línia de base de regressió de cada participant, incloses la taxa de regressió i la durada mitjana de fixació. La durada mitjana de fixació global és 248,8 ms. Les diferències individuals són notables. La taxa de regressió varia entre el 15% i el 25%, valors lleugerament més elevats que la taxa típica del 10–15% en lectors competents en anglès (Conklin et al., 2018). Aquesta variabilitat és compatible amb les diferències individuals en les estratègies de lectura, com ara la tendència a revisar segments anteriors per resoldre ambigüitats o confirmar la comprensió.

4.4.2. Tokens significatius

Calculem la puntuació *z* (unitat tipificada) per a cada token, comparant el nombre de regressions amb la línia de base del participant. Després d'aplicar la correcció de Benjamini–Hochberg¹, identifiquem 2.797 tokens de destí i 2.795 tokens d'origen significatius. És a dir, són tokens als quals els participants tornen significativament més sovint del que esperaríem per atzar.

Per validar els resultats de la puntuació *z*, fem 10.000 permutacions per a cada parell (participant, text), mantenint l'estructura de les dades. Amb la correcció de la taxa de falsos descobriments de Benjamini–Hochberg, obtenim 84 tokens de destí i 94 tokens d'origen significatius. La concordança entre els dos mètodes és moderada:

- **Destí:** 53 tokens significatius per ambdós mètodes, 2.744 només per la *z-score*, 31 només per permutació

¹Controla la taxa de descobriment fals ajustant els *p*-valors per limitar la proporció esperada de falsos positius entre tots els resultats significatius.

- **Origen:** 84 tokens significatius per ambdós mètodes, 2.711 només per la *z-score*, 10 només per permutació

La puntuació *z* identifica més tokens significatius que la permutació perquè assumeix independència entre observacions, mentre que la permutació té en compte l'estructura de les dades.

4.4.3. Punts focals de regressió lèxics

Entre tots els tokens significatius identificats, el 52,8% són paraules buides (preposicions, conjuncions, etc.), que filtrem amb la biblioteca NLTK². Per a cadascun dels 40 texts, seleccionem els 10 tokens significatius amb la puntuació *z* més alta i prioritzem els que també són significatius per permutació ($q < 0,05$). Anomenem aquests tokens *punts focals*. La [Taula 4.8](#) presenta els 40 punts focals lèxics més significatius—un per text—ordenats per puntuació *z*. En destaquem tres aspectes:

- **Paraules relacionades amb el gènere:** termes com “lesbiana”, “mujer”, “patriarcal”, “tóxica”, “parejas”, “mujeres”, “hombres”, “jerárquicas” i “femenino” apareixen sovint entre els punts focals, en consonància amb el contingut sexista dels texts. En total, 28 tokens (9,3%) fan referència directa a conceptes de gènere o a relacions de poder.
- **Distribució morfològica:** l'anàlisi de les categories gramaticals dels 300 tokens que no són paraules buides mostra que els punts focals són majoritàriament substantius (41,1%), seguits de verbs (21,9%), adjectius (16,6%) i adverbis (8,6%). En el context de gènere, molts adjectius descriuen qualitats o atributs (*lesbiana*, *tóxica*, *patriarcal*, *culturales*, *jerárquicas* i *femenino*). Els verbs sovint expressen accions o judicis (*ahorita*, *odian*, *creen* i *explicar*).
- **Direcció de regressió:** la majoria dels punts focals són tokens de destí, és a dir, tokens als quals els lectors tornen més sovint. Això suggereix que revisen elements temàticament rellevants.

4.4.4. Relació amb les anotacions de segments

Per examinar si els tokens amb més atenció ocular corresponen a les zones anotades com a sexistes, comparem els 2.881 tokens significatius segons la puntuació *z* amb les anotacions de segments del *gold standard*. Del total, 2.458 tokens significatius (85,3%) es troben dins d'un interval anotat. Això indica una forta associació entre les zones de més atenció dels lectors i les zones etiquetades com a sexistes.

No obstant això, la prova exacta de Fisher per text no aconsegueix significació estadística en cap cas, possiblement per manca de potència (mitjana de 4–10 tokens anotats per text i 10

²<https://www.nltk.org/>

Text	Destí	z	Origen	z
4	llegado	6,64	progresismo	5,16
5	lesbiana	7,11	mientras	6,88
23	sexual	6,47	Sígueme	6,79
30	forense	5,75	Feministas	4,91
37	sobrevivir	2,94	Imaginate	3,41
45	patriarcal	5,37	explicar	5,89
55	ahorita	8,14	solo	8,00
59	miren	4,64	saben	4,34
60	la	3,80	no	4,65
62	existe	5,67	hombre	5,74
76	creen	7,93	Administrativa	8,00
78	Infojobs	6,11	mercado	5,95
99	anticuado	6,25	jerárquicas	6,61
106	mujer	5,64	cumplidos	5,08
107	aquí	4,42	ley	5,17
124	nací	6,87	pena	6,95
133	real	6,42	antecedentes	6,11
136	culturales	6,66	cualidades	6,46
143	ridículo	8,75	habilidad	8,81
144	tóxica	6,82	lado	6,52
148	parejas	6,43	relacionarse	5,90
150	pide	5,75	oír	5,42
151	literalmente	7,95	favor	8,05
166	pueden	3,25	sense	3,65
201	años	7,00	siempre	6,47
214	opinas	4,64	gracias	4,83
215	Pues	5,63	beneficiado	7,00
217	bestia	5,93	lecciones	6,02
327	puedes	5,84	voy	6,22
352	marzo	5,91	abrazo	5,77
356	natural	6,47	civilización	6,59
357	supiese	6,40	cuenta	6,48
359	acceder	5,43	violación	4,85
362	voy	7,27	pasando	7,36
364	idiomas	6,92	respuesta	6,27
373	pasto	4,49	verdad	5,26
375	tema	6,33	problema	6,14
383	seguidor	5,58	largo	5,32
390	patriarcado	4,17	violentas	4,09
399	chamaquito	5,75	doña	5,43

Taula 4.8. Punts focals de destí i origen per text, sense puntuació. Destí = token on els lectors regressionen més sovint (z més alt en direcció TO); Origen = token des del qual els lectors fan més regressions (z més alt en direcció FROM).

participants). L'efecte global—el 85,3% dels tokens significatius es troben dins de segments—és molt superior al que esperaríem per atzar.

La [Taula 4.9](#) mostra la correlació de Spearman entre la cobertura de cada segment (proporció de tokens anotats) i la taxa de regressió mitjana per text, estratificada per categoria d'etiqueta. L'única correlació significativa és a la categoria “sexista”: els texts sexistes presenten taxes de regressió més altes. Per tant, els lectors semblen fer més regressions davant del contingut sexista, possiblement perquè aquest contingut requereix més reprocessament cognitiu.

Categoria	ρ	valor p	n texts
sexista	0,429	0,006 *	20
discriminació	0,273	0,088	6
crítica	-0,233	0,147	19
estereotips	0,204	0,207	14
sexisme implícit	0,199	0,218	12
humor	0,078	0,634	6

Taula 4.9. *Correlació de Spearman entre cobertura de segment (proporció de tokens anotats) i taxa mitjana de regressió per text, estratificat per categoria. n = nombre de texts amb cobertura > 0 per a cada categoria.*

4.4.5. Punts focals dins de segments per tipus d'etiqueta

A la [Taula 4.10](#) identifiquem punts focals de regressió significatius dins dels intervals anotats per a cada tipus d'etiqueta. Els ponderem per l'invers de la longitud del segment per evitar un biaix cap als segments llargs.

Etiqueta	n punts focals	z mitjà	Clúster mitjà	Long. segment
crítica	42	5,81	56,0	60,4
estereotips	30	5,98	55,1	58,1
desigualtat/discrim.	30	5,70	50,5	53,3
sexisme implícit	24	5,58	37,7	37,7
ironia	16	5,13	39,6	39,6
humor	18	5,21	29,8	47,0
desig. ideol.	10	5,20	17,2	28,6
objectificació	10	5,87	20,4	37,8
sexisme reportat	8	5,86	53,8	53,8

Taula 4.10. *Punts focals de regressió per tipus d'etiqueta de segment, ponderats per $1/\text{longitud}$.*

Crítica és l'etiqueta amb més punts focals (42), seguida d'*estereotips* (30) i de les categories *desigualtat* i *discriminació* (30 en conjunt). Els punts focals amb les puntuacions z més altes il·lustren com els lectors reprocessen regions clau del text:

- (1) **Text 143, objectificació i estereotips** (origen “Cómo”, $z = 6,65$): el text comença amb “¿Cómo ser gracioso y conquistar sin hacer el ridículo?”, un consell de seducció.

Els lectors interrompen la lectura a l'inici i tornen enrere després de llegir les situacions exemples (la dona dient “és hora d'anar al llit”), com si necessitessin verificar si la tècnica de malinterpretació intencional és realment el que es descriu. El clúster més petit per a *objectificació* (9 tokens) vs. *estereotips* (23 tokens) suggereix que la relectura per identificar l'objectificació és més localitzada, mentre que per als estereotips abasta un radi més ampli.

- (2) **Text 55, crítica** (destí “ahorita”, $z = 8,14$, clúster de 98 tokens): el text critica el feminisme dient que “no és res més que odiar als homes”. “Ahorita” és un marcador temporal que ancora la crítica al present. Els lectors tornen a rellegir des de punts posteriors fins a aquesta paraula, possiblement per situar temporalment la comparació amb els feminicidis diaris i verificar si la coherència argumentativa es manté.
- (3) **Text 76, desigualtat/discriminació** (origen “Administrativa”, $z = 8,00$, clúster de 73 tokens): el text planteja àrees de treball (minería, construcció, plataformes petrolíferes) i conclou amb “Administrativa per nosaltres”. Els lectors regressen des d'aquesta conclusió discriminatòria fins a les preguntes anteriors, reclamant el context complet de la comparació per confirmar que la ironia és efectivament sexista.

4.5. Mètriques d'eye-tracking

A més de les mètriques basades en regressions, analitzem la TFD, la FFD i la FC per token.

4.5.1. Mètriques d'eye-tracking per token

En primer lloc, comparem la TFD, la FFD i la FC mitjanes per text entre els 20 texts sexistes i els 20 no sexistes amb la prova de Mann–Whitney. La [Taula 4.11](#) mostra les mètriques mitjanes

Mètode	Sexistes	No sexistes	p
TFD (%)	$1,87 \pm 0,52$	$2,41 \pm 1,33$	0,473
FFD (ms)	$198,2 \pm 6,1$	$201,0 \pm 5,6$	0,133
FC	$1,95 \pm 0,37$	$2,03 \pm 0,37$	0,209

Taula 4.11. TFD, FFD i FC mitjanes per text segons etiqueta binària (Mann-Whitney, bilateral).

per text. Els texts no sexistes tendeixen a presentar valors lleugerament més alts de TFD, FFD i FC, però les diferències són petites i no significatives.

En segon lloc, per avaluar si els tokens dins dels segments anotats com a sexistes reben més atenció, calculem les puntuacions z de TFD, FFD i FC per participant, respecte de la seva mitjana global, i comparem els tokens dins i fora dels segments. La [Taula 4.12](#) mostra diferències significatives per a la TFD i la FC: els tokens dins dels segments anotats com a sexistes reben

Mètode	Dins segment	Fora segment	p
TFD z-score	+0,045	−0,284	< 0,001 *
FFD z-score	+0,003	−0,018	0,741
FC z-score	+0,020	−0,126	< 0,001 *

Taula 4.12. *Z-scores de TFD, FFD i FC per tokens dins ($n = 18\,708$) vs. fora ($n = 2\,973$) dels segments anotats (Mann-Whitney, bilateral).*

més fixacions i durant més temps que els tokens fora dels segments. En canvi, la FFD no presenta diferències significatives.

La [Taula 4.13](#) mostra les correlacions de Spearman entre parelles de mètriques. La TFD i la FC presenten una correlació forta ($\rho = 0,623$), com era esperable, ja que totes dues mesuren l’atenció acumulada i el reprocessament deliberat. En canvi, la FFD captura la reacció inicial, més automàtica. La correlació entre la TFD i la FFD és moderada ($\rho = 0,318$). La correlació feblement negativa entre la FFD i la FC ($\rho = -0,070$) suggereix que els tokens que reben la primera fixació més llarga no són necessàriament els que reben més visites. És possible que els lectors revisitin deliberadament els fragments sexistes, tot i que la primera impressió que els produeixen no sigui diferent de la de la resta del text. Aquest patró és coherent amb els resultats de l’anàlisi de regressions, en què els tokens dins dels segments presenten taxes de retorn més altes.

Parell	ρ de Spearman	p
TFD vs. FFD	0,318	< 0,001 *
TFD vs. FC	0,623	< 0,001 *
FFD vs. FC	−0,070	< 0,001 *

Taula 4.13. *Correlació de Spearman entre les tres mètriques d’eye-tracking per token.*

4.5.2. Prominència dels models vs. mètriques d’eye-tracking

Per extreure la prominència de cada model, fem servir quatre mètodes d’interpretabilitat: N’extraïem la prominència amb quatre mètodes d’interpretabilitat: Saliency, Input×Gradient, Integrated Gradients (IG) i Layer-wise Relevance Propagation (LRP). La [Taula 4.14](#) presenta la correlació de Spearman entre la prominència de cada token—el valor absolut de l’atribució del model—i les tres mètriques d’eye-tracking (TFD, FFD i FC), promitjades entre participants per als 40 texts. Les correlacions són positives, però febles per a la TFD i la FC. Per tant, els tokens als quals els models assignen més importància coincideixen parcialment amb els que reben més atenció dels lectors. La FFD mostra una correlació lleugerament negativa, coherent amb el fet que la primera fixació no discrimina entre zones sexistes i no sexistes, com ja hem observat.

mBERT obté les correlacions més altes ($\rho = 0,076$ per a la TFD i $\rho = 0,124$ per a la FC amb

Model	Mètode	ρ TFD	ρ FFD	ρ FC
BETO	IG	0,068	-0,036	0,113
BETO	Input×Gradient	0,068	-0,038	0,116
BETO	LRP	0,070	-0,044	0,115
BETO	Saliency	0,075	-0,042	0,122
MrBERT-es	IG	0,037	-0,062	0,083
MrBERT-es	Input×Gradient	0,045	-0,057	0,088
MrBERT-es	LRP	0,041	-0,051	0,081
MrBERT-es	Saliency	0,049	-0,054	0,092
mBERT	IG	0,070	-0,039	0,116
mBERT	Input×Gradient	0,068	-0,040	0,114
mBERT	LRP	0,081	-0,045	0,127
mBERT	Saliency	0,076	-0,042	0,124

Taula 4.14. *Correlació de Spearman: prominència del model vs. mètriques d’eye-tracking (mitjana sobre 40 texts).*

Saliency), seguit de BETO ($\rho = 0,075$ i $0,122$) i MrBERT-es ($\rho = 0,049$ i $0,092$). En mBERT, LRP mostra correlacions similars o lleugerament superiors a les de Saliency ($\rho = 0,081$ per a la FC); en la resta de models, els resultats són comparables.

4.6. Comparació entre atenció humana i prominència de models

En aquesta secció comparem tres models preentrenats (mBERT, BETO i MrBERT-es) amb dues referències: les anotacions de segments del *gold standard* i l’atenció humana mesurada amb eye-tracking. N’extraïem la prominència amb Saliency, Input×Gradient, IG i LRP.

Totes les comparacions de distribucions utilitzen filtratge de paraules buides (vegeu l’ablació a l’Apèndix E).

4.6.1. Prominència del model vs. anotacions de segments

En primer lloc, comparem les distribucions de prominència dels models amb les anotacions de segments sexistes del corpus MuSeD.

Solapament

Avaluem fins a quin punt les paraules amb més prominència coincideixen amb les paraules incloses en els segments anotats com a sexistes pel *gold standard*. La Taula 4.15 mostra la superposició per a cinc l·lindars: l’1%, el 3%, el 5%, el 10% i el 20% dels tokens amb més prominència. La superposició és alta independentment del l·lindar (87,1%–92,2%), tot i que disminueix lleugerament al 5%–10% respecte de l’1%–3%. Aquest patró suggereix que els tokens amb prominència més extrema—l’1%–3% superior—es troben gairebé sempre dins dels segments. Quan ampliem el l·lindar al 5%–10%, hi incorporem alguns tokens externs; al 20%, la proporció torna a augmentar

Model	Mètode	1%	3%	5%	10%	20%
BETO	IG	0,907	0,904	0,888	0,888	0,904
BETO	Input×Gradient	0,890	0,887	0,871	0,871	0,887
BETO	LRP	0,890	0,887	0,871	0,871	0,887
BETO	Saliency	0,890	0,887	0,871	0,871	0,887
MrBERT-es	IG	0,922	0,918	0,918	0,918	0,918
MrBERT-es	Input×Gradient	0,890	0,887	0,887	0,887	0,887
MrBERT-es	LRP	0,890	0,887	0,887	0,887	0,887
MrBERT-es	Saliency	0,890	0,887	0,887	0,887	0,887
mBERT	IG	0,919	0,916	0,900	0,900	0,916
mBERT	Input×Gradient	0,890	0,887	0,871	0,871	0,887
mBERT	LRP	0,890	0,887	0,871	0,871	0,887
mBERT	Saliency	0,890	0,887	0,871	0,871	0,887

Taula 4.15. *Solapament: paraules amb prominència més alta vs. paraules dins dels segments anotats, per a diferents llindars de selecció.*

perquè els nous tokens interns compensen aquesta incorporació. El mètode IG produeix una superposició consistentment superior a la de Saliency, Input×Gradient i LRP. Això indica que les atribucions d'IG estan més concentrades en les paraules clau dels segments.

Distribucions de prominència

La [Taula 4.16](#) compara les distribucions de prominència dels models amb les anotacions de segments.

Model	Mètode	CE	KL	JS
BETO	IG	24,45	21,15	0,781
BETO	Input×Gradient	24,55	21,26	0,795
BETO	LRP	24,71	21,43	0,790
BETO	Saliency	24,51	21,22	0,776
MrBERT-es	IG	25,56	22,32	0,830
MrBERT-es	Input×Gradient	25,69	22,40	0,837
MrBERT-es	LRP	25,67	22,36	0,833
MrBERT-es	Saliency	25,67	22,38	0,827
mBERT	IG	24,39	21,10	0,779
mBERT	Input×Gradient	24,54	21,26	0,791
mBERT	LRP	24,56	21,27	0,786
mBERT	Saliency	24,51	21,22	0,775

Taula 4.16. *Mètriques de distribució: prominència del model vs. anotacions de segment, amb paraules buides filtrades (mitjana sobre 40 texts).*

Una JS mitjana d'aproximadament 0,78–0,84 indica una divergència substancial, però no total, entre la distribució de prominència dels models i les anotacions de segments. Aquesta divergència és esperable: els segments marquen només una part del text com a sexista, mentre que la prominència es distribueix entre tots els tokens. Les diferències entre mètodes d'interpretabilitat són petites, cosa que suggereix que la distribució de prominència és similar independentment del mètode utilitzat.

Alineament per tipologia d'etiqueta

La [Taula 4.17](#) desglossa l'alineament entre la prominència dels models i l'atenció humana per tipus d'etiqueta de segment. Les xifres són una mitjana sobre les 12 combinacions de model i mètode. La variabilitat entre combinacions és moderada: el rang de JS dins de cada model entre mètodes varia de 0,16 (MrBERT-es) a 0,27 (BETO), i el rang entre models dins de cada mètode varia de 0,19 (Input×Gradient) a 0,28 (LRP). La combinació que produeix la JS més baixa és BETO amb LRP (0,789), i la més alta és MrBERT-es amb IG (0,866), cosa que indica que l'elecció del model té més pes que la del mètode.

Etiqueta	Prom. (dins)	Prom. (fora)	ρ TFD	ρ FC	JS
crítica	0,036	0,000	0,042	0,097	0,741
estereotips	0,028	0,027	0,096	0,131	0,850
sexisme reportat	0,009	0,019	-0,036	-0,012	0,887
desigualtat/discrim.	0,017	0,029	0,089	0,160	0,798
humor	0,042	0,000	0,092	0,183	0,836
ironia	0,022	0,019	0,129	0,259	0,822
sexisme implícit	0,039	0,030	0,150	0,325	0,871
objectificació	0,007	0,027	0,138	0,198	0,895
desig. ideol.	0,035	0,027	—	—	0,818

Taula 4.17. *Mètriques per tipus d'etiqueta del segment: prominència del model dins de cada tipologia (mitjana sobre texts, models i mètodes).*

Les principals observacions són les següents. *Crítica* i *humor* concentren la prominència dins del segment i no en presenten fora, cosa que suggereix que els models identifiquen clarament aquestes categories. En canvi, *sexisme reportat* i *objectificació* presenten menys prominència dins del segment que fora, fet que apunta a dificultats per identificar-les. El text 144 (“*mujer tóxica*”) n’és un cas representatiu: malgrat estar anotat com a sexista amb *estereotips* i *desigualtat*, els models no concentren la prominència en el segment, cosa que confirma la dificultat de detectar estereotips sense marcadors explícits de discriminació.

Pel que fa a les correlacions amb les mètriques d’eye-tracking, *sexisme implícit* mostra els valors més alts amb FC i TFD. Això indica que els models i els lectors coincideixen més en aquesta tipologia subtil. *Ironia* també presenta correlacions relativament altes, compatibles amb una captura similar del fenomen. Finalment, la JS més baixa correspon a *crítica*, que mostra la concordança més alta entre les distribucions dins i fora del segment.

4.6.2. Prominència del model vs. TFD

En segon lloc, la [Taula 4.18](#) compara les distribucions de prominència dels models amb l’atenció humana (TFD). La JS entre els models i la TFD (0,77–0,84) és pràcticament la mateixa que entre els models i els segments (0,78–0,84). Les diferències entre mètodes són igualment petites.

Model	Mètode	CE	KL	JS
BETO	IG	24,43	21,15	0,778
BETO	Input×Gradient	24,51	21,21	0,790
BETO	LRP	24,62	21,31	0,782
BETO	Saliency	24,47	21,17	0,770
MrBERT-es	IG	25,54	22,34	0,825
MrBERT-es	Input×Gradient	25,68	22,38	0,835
MrBERT-es	LRP	25,73	22,41	0,835
MrBERT-es	Saliency	25,66	22,37	0,825
mBERT	IG	24,35	21,09	0,777
mBERT	Input×Gradient	24,51	21,21	0,787
mBERT	LRP	24,55	21,25	0,782
mBERT	Saliency	24,47	21,17	0,770

Taula 4.18. *Mètriques de distribució: prominència del model vs. atenció humana (TFD), amb paraules buides filtrades (mitjana sobre 40 texts).*

4.6.3. Resum de les tres comparacions

La [Taula 4.19](#) resumeix les tres comparacions: models–segments, models–TFD i TFD–segments. La divergència JS més baixa és la que s’observa entre la TFD i les anotacions de segments. Llavors, anotadors i lectors comparteixen una visió similar de sexisme. La divergència més alta és la que es dona entre els models i les anotacions de segments, cosa que indica que els models de llenguatge distribueixen la prominència de manera substancialment diferent de les persones.

Parell	JS (Saliency)	JS (IG)	JS (LRP)
Model – Segments	0,78–0,83	0,78–0,83	0,79–0,83
Model – TFD	0,77–0,83	0,78–0,83	0,78–0,84
TFD – Segments	0,12 (ref.)	—	—

Taula 4.19. *Resum de divergència JS per als tres parells de distribucions, amb paraules buides filtrades. La TFD vs. segments prové de l’ablació [E.1](#) (JS mitjana = 0,12).*

4.6.4. Precisió del model i divergència KL respecte a l’atenció humana

Per comprovar si l’alineament amb l’atenció humana es relaciona amb el rendiment de classificació, seguim la proposta de Sood et al. (2020). Per a cada combinació de model i mètode, calculem la correlació entre la divergència KL respecte de la TFD i la precisió per text. La [Taula 4.20](#) recull aquestes correlacions.

Model	Mètode	Precisió (%)	ρ TFD	ρ FFD	ρ FC
BETO	IG	61,1	+0,236	+0,159	+0,208
BETO	Input×Gradient	62,2	+0,125	+0,042	+0,104
BETO	LRP	62,2	+0,308	+0,230	+0,287
BETO	Saliency	62,2	+0,193	+0,078	+0,172
MrBERT-es	IG	74,2	+0,190	+0,107	+0,223
MrBERT-es	Input×Gradient	75,7	+0,088	+0,024	+0,083
MrBERT-es	LRP	75,7	+0,024	+0,035	-0,012
MrBERT-es	Saliency	75,7	+0,083	+0,053	+0,077
mBERT	IG	57,6	-0,193	-0,174	-0,206
mBERT	Input×Gradient	54,1	-0,234	-0,203	-0,234
mBERT	LRP	54,1	-0,249	-0,249	-0,254
mBERT	Saliency	54,1	-0,259	-0,213	-0,244

Taula 4.20. *Correlació de Spearman entre divergència KL (model vs. TFD) i rendiment del model per text. Cap correlació és estadísticament significativa.*




Figura 4.1. *Dispersió KL-precisió: cada punt representa una combinació de model i mètode d'interpretabilitat. Els colors indiquen els models i les formes, els mètodes.*

La [Taula 4.20](#) i la [Figura 4.1](#) mostren la mateixa conclusió des de dues perspectives. Cap correlació és estadísticament significativa. BETO i MrBERT-es presenten correlacions generalment positives, mentre que mBERT presenta correlacions negatives; tanmateix, la variabilitat entre mètodes no permet establir una relació sistemàtica. La figura fa explícita aquesta dissociació: MrBERT-es combina una precisió més alta amb valors de KL més grans, mentre que BETO mostra el patró contrari. Per tant, la similitud amb l'atenció humana i el rendiment de classificació semblen mesurar propietats diferents, en línia amb Ikhwantri et al. (2023).

Per comprovar que aquesta conclusió no depèn de la mètrica ocular escollida, comparem la divergència KL obtinguda amb TFD, FFD i FC, seguint la proposta d'Ikhwantri et al. (2023). La Taula 4.21 presenta aquesta anàlisi de robustesa.

Model	Mètode	KL (TFD)	KL (FFD)	KL (FC)
BETO	IG	3,45	3,52	3,34
BETO	Input×Gradient	3,57	3,64	3,46
BETO	LRP	3,10	3,21	2,99
BETO	Saliency	3,38	3,48	3,27
MrBERT-es	IG	4,70	4,77	4,59
MrBERT-es	Input×Gradient	4,41	4,55	4,31
MrBERT-es	LRP	4,20	4,30	4,12
MrBERT-es	Saliency	4,42	4,54	4,33
mBERT	IG	3,86	3,91	3,76
mBERT	Input×Gradient	4,22	4,27	4,12
mBERT	LRP	3,63	3,75	3,53
mBERT	Saliency	3,75	3,86	3,65

Taula 4.21. *Divergència KL per model, mètode i mètrica ocular. Valors més baixos indiquen major similitud entre la distribució de prominència del model i l'atenció humana.*

La FC produeix valors lleugerament més baixos i la FFD, més alts en totes les combinacions, mentre que la TFD queda en una posició intermèdia. Tanmateix, no triem la TFD només perquè minimitzi la KL, sinó també perquè acumula la durada de totes les fixacions i és, per tant, la mètrica més comparable amb una distribució de prominència acumulada.

5. Conclusions

En aquest treball hem comparat els patrons d'atenció dels lectors, obtinguts a partir de dades d'eye-tracking, amb les explicacions computacionals de models de llenguatge preentrenats adaptats a la detecció de sexisme en texts en castellà. La comparació tripartida entre TFD, anotacions de segments i atribucions dels models ens ha permès caracteritzar fins a quin punt aquestes fonts convergeixen.

De l'anàlisi en destaquem quatre resultats principals. En primer lloc, observem el que anomenem la paradoxa de BETO: el model amb menor precisió (62,2%) presenta les distribucions de prominència més properes a l'atenció humana ($KL = 3,10-3,57$). Això suggereix que l'especialització en la tasca de classificació pot allunyar el model dels patrons de processament cognitiu natural, en línia amb les conclusions d'Ikhwantri et al. (2023). En segon lloc, LRP és el mètode d'interpretabilitat que produeix les distribucions més properes a l'atenció humana en tots els models ($KL = 3,10-4,20$). Una possible explicació és la seva naturalesa de redistribució de la rellevància, que conserva informació sobre la contribució de les diferents parts de l'entrada. En tercer lloc, l'anàlisi de regressions dels 300 tokens lèxics més prominents mostra que els noms (41,1%) i els verbs (21,9%) són les categories morfològiques més representades. A més, el 9,3% dels tokens està relacionat amb el gènere, cosa que indica una atenció selectiva cap als elements lingüístics vinculats al sexisme. En quart lloc, la correlació significativa entre la taxa de regressió i la classificació binària ($\rho = 0,429$, $p = 0,006$) indica que els lectors fan més regressions en texts sexistes. Aquest resultat és coherent amb la necessitat de reprocessar contingut polèmic.

La nostra expectativa inicial—que els mètodes basats en gradients estarien més alineats amb l'atenció humana—només es confirma parcialment. Tot i que LRP produeix les divergències KL més baixes, IG mostra les més altes, malgrat que tots dos mètodes es basen en gradients. Això indica que la família de mètodes d'interpretabilitat no és, per si sola, un bon predictor de l'alineament amb l'atenció humana.

A continuació, responem als objectius plantejats a la introducció i avaluem les hipòtesis formulades al marc teòric.

Objectius

Pel que fa al **primer objectiu**, hem recollit dades de seguiment ocular de 10 participants durant la lectura de 40 texts del corpus MuSeD, amb contingut sexista i no sexista. En total, hem obtingut 34.754 fixacions. Les dades mostren que els participants detecten correctament el sexisme amb una exactitud mitjana del 82,7%, fet que dona suport a la qualitat de les dades

recollides. La taxa de regressió se situa entre el 15% i el 25%.

Quant al **segon objectiu**, hem adaptat tres models preentrenats a la tasca de detecció de sexisme (MrBERT-es, mBERT i BETO) i n'hem extret explicacions amb quatre mètodes d'interpretabilitat (Saliency, Input×Gradient, Integrated Gradients i LRP). L'exactitud varia entre models: MrBERT-es (75,7%), BETO (62,2%) i mBERT (54,1%).

Respecte al **tercer objectiu**, la comparació tripartida (models-segments, models-TFD i TFD-segments) revela divergències substancials. La divergència JS més baixa s'observa entre l'atenció humana i les anotacions de segments (aproximadament 0,1). Això indica que lectors i anotadors comparteixen una visió similar del que és sexista. En canvi, la divergència entre els models i les anotacions és alta (0,78–0,84), cosa que indica que els models distribueixen la prominència de manera substancialment diferent. D'acord amb la paradoxa de BETO, la KL mostra que aquest model presenta les divergències més baixes amb l'atenció humana (2,99–3,46), malgrat tenir una precisió inferior a MrBERT-es.

Finalment, en relació amb el **quart objectiu**, no hem trobat cap correlació estadísticament significativa entre la similitud amb l'atenció humana i el rendiment del model en la classificació per text, d'acord amb la prova de Sood et al. (2020). Això suggereix que la capacitat de detectar sexisme no depèn necessàriament de l'alineament amb els patrons de processament cognitiu. També pot dependre de la capacitat del model per capturar patrons estadístics de les dades d'entrenament.

Hipòtesis

H1: Els models adaptats mostren un alineament moderat amb els patrons de lectura.

La hipòtesi es confirma parcialment. La superposició de *punts focals* entre l'atenció humana i els segments anotats és alta (60,7%–71,9%), però la distribució de prominència dels models divergeix de l'atenció humana (JS: 0,78–0,84). Es confirmen les diferències de granularitat observades per Bogaert et al. (2026): els lectors presten atenció a zones més àmplies que les anotacions de segments, mentre que els models distribueixen la prominència de manera encara més difusa.

H2: L'alineament és major per al sexisme explícit que per a l'implícit.

La hipòtesi no es confirma de manera general. Les correlacions de Spearman són properes a zero per a totes les categories, però les divergències varien. Els estereotips (JS 0,23) i l'objectificació (JS 0,24) presenten les divergències més baixes amb l'atenció humana, mentre que la desigualtat ideològica (JS 0,50) presenta la més alta. Alhora, categories implícites com el sexisme implícit (JS 0,25), l'humor (JS 0,26) i la ironia (JS 0,28) mostren un alineament relativament bo, superior al de categories explícites com la desigualtat (JS 0,37) o el sexisme reportat (JS 0,40).

H3: Les tres fonts de dades proporcionen informació complementària entre si.

La hipòtesi es confirma. Les anotacions de segments, l'atenció humana i les explicacions dels models ofereixen perspectives diferents però compatibles. L'ablació de paraules buides mostra que el filtratge redueix la divergència JS un 26,5% entre l'atenció humana i els segments. Això indica que les paraules buides contribueixen a la divergència aparent. La comparació tripartida mostra que cap font, per si sola, ofereix una visió completa del fenomen.

Limitacions i treballs futurs

La principal limitació d'aquest treball és la mida reduïda de la mostra (10 participants i 40 texts), que limita la potència estadística. Per tant, els resultats no significatius, com la prova de Fisher per text o les correlacions per categoria individual, no impliquen necessàriament l'absència d'un efecte. També cal tenir en compte que les dades de seguiment ocular s'han recollit en condicions controlades de laboratori, que poden no reflectir completament els patrons de lectura naturals.

Com a treballs futurs, proposem quatre línies: (1) augmentar la mostra amb més participants i texts; (2) explorar models de llenguatge extensos (*Large Language Model*, LLM en anglès); (3) investigar amb més detall la relació entre les atribucions dels models i les categories lingüístiques; i (4) aplicar les mètriques de distribució a altres tasques de PLN amb dades d'eye-tracking disponibles.

Referències

- Alvarez, M. (2025). *Attachment Preferences and the Processing of Syntactic Ambiguity in L1 Catalan and L2 English: An Eye-Tracking Study* [Master's Thesis]. Universitat de Barcelona.
- Arcos, I. (2025). *A Multimodal Sensor Data Based Approach to Sexism Identification in Memes Using Heart Rate Variation, Eye Tracking and EEG Signals* [Master's Thesis]. Universitat Politècnica de València. <https://doi.org/10.4995/ia.2014.3293>
- Bogaert, J., Escoufflaire, L., Descampe, A., de Marneffe, M.-C., & Standaert, F.-X. (2026). Explanation variability in text classification: Humans vs. LLMs.
- Breiman, L. (2003). Statistical modeling: The two cultures. *Quality control and applied statistics*, 48(1), 81-82.
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2023). Spanish pre-trained bert model and evaluation data. *arXiv preprint arXiv:2308.02976*.
- Clifton Jr, C., Staub, A., & Rayner, K. (2007). Eye movements in reading words and sentences. *Eye movements*, 341-371.
- Conklin, K., Pellicer-Sánchez, A., & Carrol, G. (2018, 15 de març). *Eye-Tracking: A Guide for Applied Linguistics Research* (1a ed.). Cambridge University Press. <https://doi.org/10.1017/9781108233279>
- Chakravarthi, B. R., Priyadharshini, R., Ponnusamytt, R., Kumar, P., Kumaresantft, K. S., Thenmozhi, D., Thangasamytl, S., Nallathambilr, R., & McCrae, J. P. (2021). Dataset for Identification of Homophobia and Transophobia in Multilingual YouTube Comments. *Natural Language Engineering*, 1, 00.
- Chefer, H., Gur, S., & Wolf, L. (2021). Transformer interpretability beyond attention visualization. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 782-791.
- De Grazia, L., Pastells, P., Chas, M. V., Elliott, D., Villegas, D. S., Farrús, M., & Taulé, M. (2025, 21 de agost). *MuSeD: A Multimodal Spanish Dataset for Sexism Detection in Social Media Videos*. arXiv: 2504.11169 [cs]. <https://doi.org/10.48550/arXiv.2504.11169>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, 4171-4186.

- Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological bulletin*, 76(5), 378.
- Gandhi, A., Ahir, P., Adhvaryu, K., Shah, P., Lohiya, R., Cambria, E., Poria, S., & Hussain, A. (2024). Hate speech detection: A comprehensive review of recent works. *Expert Systems*, 41(8), e13562.
- Hollenstein, N., Rotsztejn, J., Troendle, M., Pedroni, A., Zhang, C., & Langer, N. (2018). ZuCo, a simultaneous EEG and eye-tracking resource for natural sentence reading. *Scientific Data*, 5(1), 180291. <https://doi.org/10.1038/sdata.2018.291>
- Hollenstein, N., Troendle, M., Zhang, C., & Langer, N. (2020, 7 de març). *ZuCo 2.0: A Dataset of Physiological Recordings During Natural Reading and Annotation*. arXiv: 1912.00903 [cs]. <https://doi.org/10.48550/arXiv.1912.00903>
- Ikhwantri, F., Putra, J. W. G., Yamada, H., & Tokunaga, T. (2023). Looking deep in the eyes: Investigating interpretation methods for neural models on reading tasks using human eye-movement behaviour. *Information Processing & Management*, 60(2), 103195. <https://doi.org/10.1016/j.ipm.2022.103195>
- Jacovi, A., & Goldberg, Y. (2020). Towards faithfully interpretable NLP systems: How should we define and evaluate faithfulness? *Proceedings of the 58th annual meeting of the association for computational linguistics*, 4198-4205.
- Jain, S., & Wallace, B. C. (2019, 8 de maig). *Attention Is Not Explanation*. arXiv: 1902.10186 [cs]. <https://doi.org/10.48550/arXiv.1902.10186>
- Just, M. A., & Carpenter, P. A. (1980). A theory of reading: from eye fixations to comprehension. *Psychological review*, 87(4), 329.
- Kokhlikyan, N., Miglani, V., Martin, M., Wang, E., Alsallakh, B., Reynolds, J., Melnikov, A., Kliushkina, N., Araya, C., Yan, S., et al. (2020). Captum: A unified and generic model interpretability library for pytorch. *arXiv preprint arXiv:2009.07896*.
- Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *biometrics*, 159-174.
- Lipton, Z. C. (2018). The mythos of model interpretability: In machine learning, the concept of interpretability is both important and slippery. *Queue*, 16(3), 31-57.
- Malik, J. S., Qiao, H., Pang, G., & van den Hengel, A. (2025). Deep learning for hate speech detection: a comparative study. *International Journal of Data Science and Analytics*, 20(4), 3053-3068.
- O'Brien, J. (2009). *Encyclopedia of gender and society* (Vol. 1). Sage.

- Pickering, M. J., Frisson, S., McElree, B., & Traxler, M. J. (2004). Eye movements and semantic composition. A *The on-line study of sentence comprehension* (p. 33-50). Psychology Press.
- Plaza, L., Carrillo-de-Albornoz, J., Arcos, I., Rosso, P., Spina, D., Amigó, E., Gonzalo, J., & Morante, R. (2025). Overview of exist 2025: Learning with disagreement for sexism identification and characterization in tweets, memes, and tiktok videos. *International Conference of the Cross-Language Evaluation Forum for European Languages*, 266-289.
- Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022, 6 de desembre). *Robust Speech Recognition via Large-Scale Weak Supervision*. arXiv: [2212.04356](https://arxiv.org/abs/2212.04356) [eess]. <https://doi.org/10.48550/arXiv.2212.04356>
- Rayner, K. (1998). Eye movements in reading and information processing: 20 years of research. *Psychological bulletin*, 124(3), 372.
- Rayner, K. (2009). Eye movements and attention in reading, scene perception, and visual search. *The quarterly journal of experimental psychology*, 62(8), 1457-1506.
- Samory, M., Sen, I., Kohne, J., Flöck, F., & Wagner, C. (2021). “Call me sexist, but...”: Revisiting Sexism Detection Using Psychological Scales and Adversarial Samples. *Proceedings of the international AAAI conference on web and social media*, 15, 573-584.
- Schmeisser-Nieto, W., Nofre, M., & Taulé, M. (2022). Criteria for the annotation of implicit stereotypes. *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, 753-762.
- Shrikumar, A., Greenside, P., Shcherbina, A., & Kundaje, A. (2016). Not just a black box: Learning important features through propagating activation differences. *arXiv preprint arXiv:1605.01713*.
- Simonyan, K., Vedaldi, A., & Zisserman, A. (2013). Deep inside convolutional networks: Visualising image classification models and saliency maps. *arXiv preprint arXiv:1312.6034*.
- Sood, E., Tannert, S., Frassinelli, D., Bulling, A., & Vu, N. T. (2020, novembre). Interpreting Attention Models with Human Visual Attention in Machine Reading Comprehension. A R. Fernández & T. Linzen (Ed.), *Proceedings of the 24th Conference on Computational Natural Language Learning* (p. 12-25). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.conll-1.2>
- Sundararajan, M., Taly, A., & Yan, Q. (2017). Axiomatic attribution for deep networks. *International conference on machine learning*, 3319-3328.
- Szymanski, D. M., Moffitt, L. B., & Carr, E. R. (2011). Sexual objectification of women: Advances to theory and research 1ψ7. *The counseling psychologist*, 39(1), 6-38.

- Tamayo, D., Lacunza, I., Rivera-Hidalgo, P., Da Dalt, S., Aula-Blasco, J., Gonzalez-Agirre, A., & Villegas, M. (2026). MrBERT: Modern Multilingual Encoders via Vocabulary, Domain, and Dimensional Adaptation. *arXiv preprint arXiv:2602.21379*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023, 2 de agost). *Attention Is All You Need*. arXiv: 1706.03762 [cs]. <https://doi.org/10.48550/arXiv.1706.03762>
- Wiegrefe, S., & Pinter, Y. (2019, 5 de setembre). *Attention Is Not Not Explanation*. arXiv: 1908.04626 [cs]. <https://doi.org/10.48550/arXiv.1908.04626>
- Yang, Z., Dai, Z., Yang, Y., Carbonell, J., Salakhutdinov, R. R., & Le, Q. V. (2019). Xlnet: Generalized autoregressive pretraining for language understanding. *Advances in neural information processing systems*, 32.

A. Funcionament de l'eye-tracker

Utilitzem l'eye-tracker Tobii Pro Spectrum, que registra la zona de la pantalla que mira el participant a 600 Hz. El programari Tobii Pro Lab calcula les fixacions i permet definir cada paraula d'un text com una àrea d'interès (AOI, per les sigles en anglès). El programari permet calcular algunes mètriques, però presenta limitacions en aspectes com el càlcul de regressions. Per això exportem les dades i calculem les mètriques d'eye-tracking—FFD, TFD, FC i regressions—de manera independent.

El problema és que Tobii Pro Lab no optimitza el format d'exportació. En comptes de crear un fitxer per a cada text, crea un fitxer amb tots els instants com a files i totes les AOI com a columnes. Per tant, la mida del fitxer creix quadràticament amb el nombre de texts i el programa es bloqueja. Per optimitzar aquest procés, vam exportar diversos fitxers de la manera següent¹. Sempre vam utilitzar el filtre *Tobii I-VT (Fixation)* i l'opció *noise reduction*, tant per a l'obertura de l'ull com per al diàmetre de la pupil·la:

1. **Dades generals:** inclouen el dia, l'hora i els resultats del calibratge. Es van seleccionar el grup General, excepte AOI size, timestamp i event value; un sol Time of interest i cap AOI.
2. **Anotacions:** inclouen les entrades de teclat dels participants. Es van seleccionar Participant name, Event i Event value; Times of Interest = Media gaze data i cap AOI.
3. **Dades del sensor:** cal seleccionar grups petits d'AOI i els temps corresponents a Times of interest. Finalment, es van crear quatre grups de 10 texts per participant. Es poden exportar simultàniament en fitxers individuals amb *Format=multiple standard files*. Després, vam convertir els fitxers exportats al format *parquet*, més eficient.

- General: Participant name
- Eye tracking data: Pupil diameter, Validity of eye data
- Media: stimulus name
- Eye movement events: eye movement type, duration and index, fixation point, AOI hit

¹Dins del menú Analyze/Data export

B. TFD i regressions

B.1. Durada total de fixació (TFD)

La durada total de fixació (*Total Fixation Duration*, TFD) mesura l'atenció acumulada en una AOI al llarg de tota la lectura. Es calcula com la suma de les durades de totes les fixacions que cauen dins d'una AOI concreta. En el nostre cas, la normalitzem pel temps total de fixació de cada text:

$$\text{TFD}_i = \frac{\sum_{k \in \text{fixacions}_i} d_k}{\sum_{j=1}^N \sum_{k \in \text{fixacions}_j} d_k}$$

on d_k és la durada de la fixació k , i és l'índex del token (AOI) i N és el nombre total de tokens del text. Aquesta normalització ens permet comparar patrons d'atenció entre participants amb velocitats de lectura diferents. Una TFD més alta en un token indica que els participants hi dediquen proporcionalment més temps d'atenció total. En contexts de sexisme, una TFD més alta en paraules amb càrrega emotiva o ideològica pot indicar un processament més profund del contingut discriminatori.

B.2. Regressions

Una regressió ocorre quan la mirada es desplaça cap enrere—de dreta a esquerra en texts escrits d'esquerra a dreta—respecte de la posició actual de lectura. Les regressions són un fenomen cognitiu ben documentat en la recerca sobre lectura (Rayner, 1998, 2009) i reflecteixen processos de reprocessament, verificació o resolució d'ambigüitat. Se'n distingeixen dos tipus. Les regressions intralínia (*within-line*) es produeixen quan el lector mou la mirada dins de la mateixa línia cap a un token anterior. S'associen principalment a dificultats de comprensió local, com ara paraules amb diversos significats o estructures sintàctiques complexes. Les regressions interlínia (*between-line*) es produeixen quan la mirada salta a una línia anterior. Es relacionen amb processos de coherència global, com ara connectar informació prèvia amb el contingut actual.

La taxa de regressió es defineix com la proporció de sacades que són regressions respecte al total de sacades:

$$r = \frac{n_{\text{regressions}}}{n_{\text{sacades}}} = \frac{n_{\text{regressions}}}{n_{\text{fixacions}} - 1}$$

En condicions normals de lectura, la taxa de regressió se situa entre el 10% i el 15% del

total de sacades (Rayner, 2009). Taxes més altes indiquen fragments que generen més dificultat de processament. Aquestes mètriques s'han utilitzat àmpliament en estudis sobre processament de frases i ambigüitat sintàctica. Per exemple, Alvarez (2025) mostren que les regressions són especialment informatives per identificar les regions que generen dificultat en parlants de català L1 i anglès L2.

En l'anàlisi de regressions, fem servir les definicions de *regression-to* i *regression-from* (Rayner, 2009). El token de destí és aquell cap al qual es dirigeix la regressió i indica on torna el lector per reprocessar la informació. El token d'origen és aquell des del qual es produeix la regressió i indica on interromp el lector la lectura per tornar enrere. Per exemple, si un participant està llegint el token t_{10} i fa una regressió cap al token t_5 , aquesta es registra com FROM = t_{10} , TO = t_5 . Aquesta convenció (*regression-to* / *regression-from*) és estàndard en la literatura sobre eye-tracking i lectura (Rayner, 2009). En el context del sexisme, les regressions poden indicar moments en què el lector torna a processar contingut discriminatori o irònic. Això pot ajudar a identificar regions que generen confusió o conflicte cognitiu.

Per identificar els tokens significatius, fem servir un test de permutació. Per a cada parell (participant, text), permutem aleatòriament l'ordre de la seqüència de fixacions, però mantenim la distribució global de fixacions per token. Així generem una distribució nul·la en què les regressions són aleatòries i la comparem amb les observades per determinar quins tokens reben més regressions de les esperables per atzar.

C. Calibratge i validació

Per a tots els participants, es va fer una calibració inicial amb 9 punts d'entrenament i 4 de validació. La [Taula C.1](#) presenta les mètriques de calibratge i validació de l'eye-tracker Tobii Pro Spectrum per a cada participant.

Participant	Sexe	Precisió Calibratge (mm)	Precisió Validació (mm)
M1	home	1,7	2,9
M2	home	2,3	7,5
M3	home	1,0	2,8
M4	home	1,7	2,8
M5	home	1,2	4,4
F1	dona	1,2	12,5
F2	dona	1,2	5,6
F3	dona	1,3	5,1
F4	dona	3,8	6,2
F5	dona	1,5	5,7

Taula C.1. *Precisió de calibratge i validació de l'eye-tracker per participant (en mil·límetres). Els valors més baixos indiquen una qualitat de calibratge millor.*

La majoria dels participants presenten una precisió de calibratge adequada ($\leq 2,3$ mm). Les participants F1 i F4 mostren una precisió de validació pitjor (12,5 i 6,2 mm, respectivament). Tot i això, els seus patrons de lectura permeten identificar quina paraula miren en cada moment.

En canvi, tot i presentar una precisió de validació de 5,6 mm, les dades de F2 no són tan clares. En alguns casos sembla que llegeixi entre línies o fins i tot la línia equivocada. Per això vam avaluar l'impacte d'excloure-la de l'anàlisi. La [Taula C.2](#) compara les mètriques principals amb les seves dades i sense.

Mètrica	Amb F2 (10)	Sense F2 (9)	Delta
Spearman (vs. segments)	+0,036	+0,047	+0,010
JS (vs. segments)	0,257	0,256	-0,000

Taula C.2. *Comparació de mètriques de distribució F2 i sense. Els valors són promitjats sobre els 40 texts.*

Les diferències són negligibles: la correlació de Spearman canvia en 0,01 i la divergència JS en menys de 0,001. La prova per a mostres aparellades, aplicada per text, no mostra diferències significatives ni per a Spearman ($p = 0,47$) ni per a la JS ($p = 0,11$). Concloem que l'exclusió de la participant F2 no altera substancialment els resultats de l'anàlisi. Per tant, conservem les seves dades en tots els resultats.

D. Prominència per categories gramaticals

Seguint l'anàlisi de Ikhwantri et al. (2023), comparem la distribució de prominència dels models segons les categories gramaticals amb l'atenció humana (TFD). Per a cada text, calculem la TFD mitjana dels 10 participants, etiquetem els tokens amb spaCy¹ (`es_core_news_sm`), sumem la prominència—o la TFD—dels tokens de cada categoria i normalitzem els valors perquè sumin 1,0. La Figura D.1 mostra la distribució del model més ben alineat (BETO LRP), del menys ben alineat (MrBERT-es IG) i de l'atenció humana (TFD).




Figura D.1. Distribució de prominència per categoria gramatical: atenció humana (TFD) vs. millor model (BETO LRP) i pitjor model (MrBERT-es IG).

Els resultats mostren divergències entre els models i l'atenció humana. Els lectors dediquen una proporció més alta de la seva atenció als determinants (*DET*: 9,7% vs. 6,0%–6,4%) i als auxiliars (*AUX*: 5,5% vs. 3,2%–3,5%), dues categories funcionals que els models subvaloren. En canvi, BETO LRP sobrevalora els noms (*NOM*: 20,4% vs. 15,5%) i els adjectius (*ADJ*: 8,6% vs. 4,7%). Això suggereix que el model centra la prominència en elements lèxics de contingut, mentre que els lectors la distribueixen més entre les categories gramaticals. MrBERT-es IG presenta una distribució més propera a la humana en els noms (13,2%), però subvalora els verbs (*VERB*: 13,4% vs. 14,0%). Tots dos models subvaloren els adverbis (*ADV*: 2,9%–4,0% vs. 5,2%). Aquests resultats són coherents amb els d'Ikhwantri et al., que observen que els models tendeixen a sobreponderar els adjectius i els noms en comparació amb els humans.

¹<https://spacy.io/>

E. Ablació del filtratge de paraules buides

Avaluem l'impacte del filtratge de paraules buides (*stopwords*) sobre les mètriques de distribució, utilitzant la TFD com a característica d'eye-tracking. La [Taula E.1](#) mostra la divergència JS per a les tres parelles de distribucions (TFD-segments, models-segments i models-TFD), amb filtratge de paraules buides i sense. El filtratge redueix la JS en tots els casos. L'efecte és més accentuat en la comparació TFD-segments (26,5%), perquè les paraules buides reben una atenció similar dels lectors, però no contribueixen a discriminar entre zones sexistes i no sexistes. L'efecte és menor, però consistent en les comparacions que inclouen els models (5,3%–8,3%), fet que confirma que el filtratge millora la discriminació en totes les parelles. Per aquest motiu, totes les comparacions amb els models que presentem al capítol de resultats utilitzen distribucions amb les paraules buides filtrades.

Parella	JS (tots)	JS (filtrat)	Δ
TFD-Segments (TFD)	0,137	0,100	−26,5%
Model-Segments (BETO LRP)	0,827	0,768	−7,1%
Model-TFD (BETO LRP)	0,827	0,783	−5,3%
Model-Segments (MrBERT-es IG)	0,859	0,788	−8,3%
Model-TFD (MrBERT-es IG)	0,865	0,804	−7,0%

Taula E.1. Ablació: efecte del filtratge de paraules buides sobre la divergència JS per a les tres parelles de distribucions (TFD com a característica d'eye-tracking).

F. Llista completa de texts

La [Taula F.1](#) presenta els 40 texts seleccionats del corpus MuSeD i les seves categories binàries. Primer es mostren els 20 texts sexistes i, després, els 20 no sexistes.

ID	Classificació	Texto
4	sexisme, discriminació, humor	Si crees que habíamos llegado a los límites de la incoherencia y la locura, estabas muy equivocado. Ahora, a aberraciones como estas, la pedofilia, las queremos llamar orientación sexual. Refrinos de la ley nunca había sido tan sencillo en este país. ¿Qué será lo siguiente? ¿Llamar al asesinato hobby? Vamos al declive, sin frenos, pero que todo sea por el progresismo.
5	sexisme, discriminació, ironia	Creo que soy lesbiana. Pedro, no puedes ser lesbiana porque eres un hombre. Pero si lo piensas bien, todo encaja. Yo no era una mujer atrapada en el cuerpo de un hombre. Soy una lesbiana atrapada en el cuerpo de un gay. Por eso, aun siendo gay, soy un hombre al que le atraen las mujeres. O sea que eres heterosexual. No, porque me siento mujer. Pero con una mujer no dejo de ser hombre. Soy un hombre lesbiana. No, si mientras tú lo tengas claro...
30	sexisme, discriminació, humor	Qué difícil ser forense en esta época. Imagina esta situación. Llega un cuerpo no identificado a la morgue. Forense, el cuerpo corresponde a una persona del género masculino. Feministas, ¿por qué asume su género? Forense, bueno, el cuerpo, de acuerdo a las características físicas y biológicas, corresponde a una persona del sexo masculino. Feministas, ¿por qué asume su sexo?
59	sexisme, desigualtat, estereotips, ironia	Mi gente, mi gente, miren, disfruten de estos juguetes, disfruten de estos juegos que traen plancha, lavadora, que traen así, porque las feministas pronto van a protestar que las niñas no deben jugar con esto. Así que ya ustedes saben, disfrútenlo ahora, que cuando venga el momento la van a continuar todo eso, ya lo saben.
62	sexisme, estereotips	Tres grandes razones por las que existe la brecha salarial. Primera razón. Tranquila, te lo voy a resumir en una sola razón. Y por favor, tatúaos esto en cada nalga. Para una mujer, el éxito es opcional. En cambio, para un hombre, es obligatorio. Al menos si quiere mantenerse relevante en el mercado romántico-sexual. En otras palabras, un hombre se está jugando su descendencia.
76	sexisme, estereotips	¿Necesitamos a los hombres? No. ¿Ustedes creen que prosperarían o en cuántos meses creen que la sociedad, la civilización colapsaría? Es una muy buena pregunta, no, si eso sería... ¿De que colapsaría? Colapsaría, sí. ¿En cuántos meses? No sé, pero de que colapsa uno, colapsa. ¿Ustedes de pronto a qué áreas se enfocarían? ¿A la minería? ¿A la construcción? ¿A las plataformas petroleras? ¿Electricidad en las torres? Administrativa. ¿Administrativa? Administrativa. Administrativa por nosotros.
106	sexisme, estereotips, sexisme implícit	Nunca devuelvas un cumplido. Si una mujer te dice que bien te ves hoy, que bonita te queda esa camiseta recíballo, reafirmelo más bien. Pero no, que vamos y hacemos. Ay, tu también te ves muy linda, tu cabello está muy hermoso, ¿por qué tenemos que devolver el cumplido? Eso está demostrando que tu no recibes cumplidos, que no es normal para ti.
107	sexisme, desigualtat	Les saludamos de aquí de la vigilia de oración de 40 días por la vida. Estamos atrás del Congreso de la República. Los invitamos a todos los guatemaltecos de cualquier religión para que nos unamos en defensa de la vida y nunca sea aprobada la ley del aborto en Guatemala.

ID	Classificació	Texto
143	sexisme, estereotips	¿Cómo ser gracioso y conquistar sin hacer el ridículo? Mi hermano, una habilidad clave para ser gracioso y atractivo es la malinterpretación intencional. Esta técnica te hace parecer ingenioso porque tomas las palabras de los demás, las malinterpretas, y luego la otra persona se explica. Por ejemplo, si en una cita una mujer dice, es hora de irme a la cama, podrías responder con una cara seria, sí, pero tú en la tuya y yo en la mía, me estoy guardando para el matrimonio. Es probable que la hagas reír y que incluso sienta la necesidad de explicarse que no quiso decir eso. Este tipo de respuesta rápida y con humor abre la puerta a una conexión más profunda. Recuerda usar el sentido del humor en momentos precisos y no todo el tiempo, ya que hay una línea delgada entre ser atractivo y parecer un payaso. Mi hermano, si quieres aprender más sobre cómo dominar esta habilidad, ve al enlace de mi perfil.
144	sexisme, desigualtat, estereotips	¿Cómo es una mujer tóxica? Una mujer tóxica es la que no te quiere perder, pero no sabe cuidarte. Es la que no te suelta, pero tampoco sabe retenerte. Es la que dice que te quiere, pero hace cosas que te hieren. Es la que te dice que te extraña, pero no hace nada por buscarte. Es la que no te da paz, pero tampoco te deja en paz. Este tipo de mujeres quieren que te quedes a su lado, pero jamás te harán feliz.
148	sexisme, estereotips, sexisme implícit	Mujeres diciéndole a sus parejas, yo no te pedí que lo hicieras, pero esas mismas mujeres diciendo, si te lo tengo que pedir, ya no lo quiero. ¿Qué tal y sólo qué tal que como mujeres dejamos de normalizar actitudes inmaduras y caprichosas y comenzamos a comunicarnos de manera asertiva? No sé, se me ocurre. Y luego nos preguntamos por qué los hombres están hasta aquí de relacionarse con mujeres.
150	sexisme, estereotips	Cuando mi jefe me pide que me quede 5 minutos y llevo 2 horas. [HABLANTE 0]: ¿Sabes quién es mi esposa? Escucha este mensaje. Ya se volvió loca. [HABLANTE 1]: Si estás con otra mujer haciéndolo, te voy a romper todo. [HABLANTE 0]: Y no querrás oír el resto.
151	sexisme, desigualtat	[HABLANTE 1]: ¿Por qué es una falta de respeto? [HABLANTE 0]: Porque es, literalmente, menospreciar, despreciar lo que yo creo. Es como si yo vengo y te digo, es que el cristianismo me parece un canto. [HABLANTE 2]: Para un segundo, date cuenta, por favor, date cuenta de lo que acabas de hacer. Acabas de comparar al feminismo con una religión. O sea, estás comparando que tú estás en una secta. [HABLANTE 0]: La religión es... No, no, no, perdona, no es una secta, punto número uno. [HABLANTE 2]: El feminismo es una secta. [HABLANTE 0]: O sea, ni siquiera te estoy comparando con la religión. Te estoy diciendo que son ideologías. A mí la religión, el estatus... [HABLANTE 2]: La religión no es una ideología, la religión es una creencia, una fe. No tiene nada que ver, no compares, por favor. [HABLANTE 0]: ¿Y una ideología? [HABLANTE 2]: No, no.
201	sexisme, estereotips	que responder si una mujer te dice cuántos años crees que tengo. Mi hermano recuerda que si en realidad quieres que una mujer se sienta atraída por ti entonces tienes que hacerle bromas, jugar con ella, desafiarla y molestarla. Por ejemplo, si es muy joven dile pareces de 30 aunque bien podría ser mayor y si es muy mayor dile apuesto a que este año cumples 15 no es así esto hará que su interés hacia ti aumente ya que no estás tratando forzosamente de quedar bien con ella en todo momento. Claro que no siempre te preguntarán lo mismo pero por lo menos ya sabes.
327	sexisme, estereotips	No puedes, no puedes validar a una mujer sin escalar, porque cuando lo haces, ella percibe que tú no estás valorando tu atención, que es uno de los activos más poderosos que tienes. Y entonces ella toma tu validación y dice, muy bien, me la quedo y ahora me voy a por este otro.

ID	Classificació	Text
356	sexisme, desigualtat, discriminació	Sí a la familia natural, no a los lobbies LGBT, sí a la identidad sexual, no a la ideología de género, sí a la cultura de la vida, no al abismo de muerte, sí a la universidad de la Cruz, no a la violencia islamista, sí a fronteras seguras, no a la inmigración masiva, sí al trabajo de nuestros ciudadanos, no a las grandes finanzas internacionales, sí a la soberanía de los pueblos, no a los burócratas de Bruselas, y sí a nuestra civilización, y no a quienes quieren destruirlo.
357	sexisme, desigualtat, discriminació	Si la gente supiese que los padres de la ideología de género eran pedófilos, si la gente supiese que las primeras teóricas del feminismo radical eran defensoras de la pedofilia, y aquí te hablo de Simone de Beauvoir, la cual con Sartre abusaba de menores, te hablo de Kate Millett y te hablo de Shulamith Firestone, que además era una sujeta, que despreciaba a la familia como institución y que acabó sola y encontraron su cadáver días después ya podrido, pues te das un poco cuenta de la terva de gente que formaron estas ideas.
373	sexisme, discriminació	El día de gritar, el pasto es verde, los niños tienen pene y las niñas vagina, el sexo es binario, la biología es real, la ideología de género es un cáncer. Este gobierno es el más totalitario y instructivo de nuestra democracia y Vox es el único partido que defiende y defenderá el bien, la verdad y la belleza.
375	sexisme, desigualtat	Igual por el tema del feminismo. Si ahora mismo eres un hombre que es antifeminista o que no está de acuerdo con el feminismo, eres un hombre malo, patriarcal, opresor. Si tú eres un hombre que apoya el movimiento feminista, tú no debes ir a las marchas feministas porque eso es un espacio para mujeres que tienes que entender que tú como hombre puedes suponer una amenaza o un problema. Todo ofrende, todo molesta.
383	sexisme, estereotips	entonces él es seguidor y ella es la líder pero ella nunca se va a sentir así feliz como mujer ella puede ser la líder en la vida de ella como mujer, como cantante en su trabajo pero en una relación la mujer tiene que volverse femenina pero ella está en su rol masculino aquí y él está en su rol femenino lo cual no va a funcionar esta relación a un largo plazo
23		¿Conoces la psicología de la diversidad sexual y de género, mejor conocida antes como psicología afirmativa LGBT? Esta se centra en comprender las múltiples formas en las cuales una persona puede descubrir, sentir, expresar, vivenciar y construir su identidad, su expresión de género, así como su orientación sexoafectiva. Esta parte de la psicología, o mejor dicho, esta especialidad, se centra justamente en ayudar a las personas en todo este proceso fuera del marco heteronormativo. ¿Quieres saber más? ¡Sígueme para futuros videos!
37	humor, ironia	Imaginate siendo mujer. Caminar solo de noche en Argentina y sobrevivir. Tendría que ser reconocido como un logro para el CV.
45		El sistema de ideas patriarcal se materializa en lo laboral por medio de mecanismos que las teóricas llaman el techo de cristal o el piso pegajoso. Para poder verlo es muy interesante el documental Misrepresentation, está en Netflix, o puedes preguntarle a alguna chica que sea feminista, yo creo que ellas son las más indicadas para explicar este tipo de cosas.
55	crítica	Lo que está haciendo el feminismo ahorita es nada más odiar al hombre. A ver, a las feministas nos exigen aclarar que no odiamos a los hombres. Sin embargo, aquí en México contamos con 12 feminicidios diarios con comentarios de hombres misóginos, machistas, y que aparte llegan a ser violentos y agresores con las mujeres, y ellos no les cuestionan que odian a las mujeres. Incluso se encubren entre ustedes, ni siquiera rompen el pacto patriarcal. En fin, si no nos escuchan y van a minimizar nuestro movimiento a solo odiar al hombre, haremos lo mejor, ¡cantar! ¡Cantar!
60		Nada justifica la violencia que este sistema patriarcal nos ha instaurado. Los hombres salen con una mujer que acaban de conocer y no amanecen muertos.

ID	Classificació	Text
78	crítica	¡Ojo a lo que te preguntan en Infojobs en una encuesta para acceder a un trabajo! Si eres mujer, ¿hay alguna posibilidad de que estés embarazada? ¿Y qué tendrá eso que ver con tu desempeño como dependienta? Pero después tenemos que aguantar un montón de señores que nos dicen que esto no sucede y que las mujeres no tenemos ningún tipo de barrera para acceder al mercado laboral. Y una vez más, ¡patriarcado!
099	crítica	¿Hombres alfa? ¿Qué? No solo es anticuado, sino peligroso vender la idea de que un hombre de verdad tiene que ser dominante, insensible. En la lucha contra el patriarcado estas ideas son un obstáculo. No se necesitan más machos alfa, necesitamos hombres que respeten de ser torres del pacto patriarcal. Esto es lucha callejera. El hombre no es sinónimo de dominar, poder, relaciones jerárquicas o reprimir emociones.
124	crítica, sexisme reportat	pero yo nací con un móvil en la mano, nací en primero la eso de que ya me estaba viendo mi cuerpo como una cuestión sexualizada por niños de mi misma edad y que yo veía a mi compañera, la veía sexualizándose en Instagram y veía que tenía a muchos hombres detrás y yo también quería, entonces yo también lo hago y cuesta mucho desarraigarse, ¿no? Esa sexualización que estamos viviendo las mujeres y es una pena y eso lo tienes que entender.
133	crítica	Tu comentario siento que resalta un problema real en el feminismo, porque sí, la sororidad es un concepto que viene principalmente de mujeres blancas y siento que ahí está la clave, porque la sororidad debe de ser inclusiva, debe representar a todas las mujeres, no solo las realidades de las mujeres blancas o rubias. Entonces siento que debemos de cambiar ese concepto o cambiar incluso la palabra y hacer que congeñe con nuestra raza, con nuestros antecedentes y con nuestra cultura.
136		¿Masculino o femenino? Olvidalo, son solo etiquetas culturales, no verdades biológicas. ¿Masculino o femenino? ¿Qué importa? El feminismo nos enseña que el género es un espectro. Somos más que femenino o masculino. Somos individuos únicos, con identidades que van más allá de las normas. Así que la próxima vez que escuches Esencia de Género, recuerda, somos seres humanos. Todos podemos lograr ser femenino o masculino. Esto es Lucha Callejera. La esencia de lo femenino y lo masculino no son rasgos físicos, son cualidades que todos podemos aprender y expresar.
166	crítica, humor	Espera, pero si los hombres no pueden controlarse cuando ven a una mujer en minifalda, ¿quién les dejó controlar el Estado, la política y la banca? Makes no sense. Gracias.
214		[HABLANTE 1]: ¿Qué opinas sobre el amor romántico? [HABLANTE 0]: Creo que el amor va más allá de lo bonito y todo, que no es a lo que se llega o lo que nos enseñan, que nos diferencia a las películas o todo eso. [HABLANTE 2]: Muchas gracias.
215	crítica	¿El amor romántico? Pues que es una falacia. ¿Por qué? Pues porque la realidad es mucho más compleja. En realidad no siempre, a veces el amor no es suficiente dentro de lo que promueve el feminismo. Deshacernos de este tipo de constructos sociales que llevan tantos siglos existiendo y que realmente no nos ha beneficiado a nosotras, especialmente como mujeres.
217	crítica	La bella y la bestia, un clásico ¿no? Pero debajo de ese cuento se esconde el juego del verdugo y el salvador. Aterricemos, eso no es amor. Nos venden la idea que el amor lo cambia todo, incluso a los abusadores. Pero en la vida real, las relaciones no deberían de salvar o ser salvados. Debería de ser de igualdad y respeto. El amor no es rehabilitación, esto es lucha callejera. Y es hora de cuestionar estos cuentos y sus peligrosas lecciones de amor romántico.
352	crítica	Hola familia, hoy primero de marzo se conmemora el Día Internacional de la Cero Discriminación. Todas las personas poseen talentos y habilidades que engrandecen a las comunidades. Nadie debe ser objeto de discriminación sobre la base de su género, identidad de género, raza, edad, discapacidad, origen étnico, sexo, orientación sexual, religión, idioma. Recuerda que ser diferente no es un problema, el problema es ser tratado de diferente. Un fuerte abrazo, se les quiere.

ID	Classificació	Texto
359		Tu vida, tu cuerpo. Para acceder a un aborto por violación, debes acudir a un servicio público o privado. Decir que fuiste violada, que estás embarazada y que deseas abortar. En el caso de menores de edad, pueden asistir al centro de salud solas, sin acompañamiento de padres o representantes legales. Recuerda que el aborto por violación en el Ecuador es legal.
362	crítica	vamos a decirlo así hay que ir empezando y voy a decirlo en el caso de los hombres a cuestionarnos ese tipo de lo que significa ser hombres de esta masculinidad hegemónica en donde pues también nos está afectando así como esta masculinidad hegemónica afecta muchísimo a las mujeres por tener nuestras conductas machistas, el machismo también nos afecta a nosotros como hombres o sea es darse cuenta que como dicen coloquialmente nos estamos dando nosotros el tiro al pie también o sea nos estamos pasando a afectar porque no nos permitimos sentir sacar, expresar
364	crítica	De todos los idiomas del mundo, Lucía Cirmi decidió hablar con la verdad. Es fantástico, a ver hordas de varones preocupados por la igualdad de género en la edad jubilatoria. Los quiero ver a todos, a todos, exigiendo su licencia por paternidad igualitaria, entrando a los chats de más papis de la escuela y encargándose de cosas. Limpiando su propia casa, planchando, cuidando. No, es maravilloso. ¿Qué opinan al respecto? Para mí fue una respuesta al pie. Perfecta.
390		¿Qué es el patriarcado? Es un sistema social establecido históricamente por los varones que en forma individual y colectiva oprimen a las mujeres. El patriarcado se apropia de la fuerza productiva, reproductiva en nuestras cuerpas de formas violentas o pacíficas.
399		¿Verdad? Cuando tú eres un chamaquito, ¿a quién le regalan el coche y el bebé? Se lo regalan a la nena. ¿Por qué? Si él también va a ser padre. Él también algún día va a usar el coche, ¿me entiendes? Esas cosas no tienen género. Entonces, cuando tú creces, te ponen en la mente que coser es para la nena, para la abuelita, para la doña, ¿me entiendes?

Taula F.1. *Llista completa dels 40 texts seleccionats, amb les categories binàries assignades. Els texts amb intervencions de diversos parlants (HABLANTE) es van reenumerar i es van separar en línies diferents per a cada parlant durant l'experiment.*